


Prepárate para convertirte en Professional Data Engineer




Cuaderno de ejercicios del curso

Secciones de la guía del examen para la certificación

- | | |
|---|--|
| 1 | Diseño de sistemas de procesamiento de datos |
| 2 | Transferencia y procesamiento de datos |
| 3 | Almacenamiento de los datos |
| 4 | Preparación y uso de los datos para el análisis |
| 5 | Mantenimiento y automatización de las cargas de trabajo de datos |



Sección 1: Diseño de sistemas de procesamiento de datos



1.1 | Pregunta de diagnóstico 1



Los analistas de negocios de tu equipo tienen que ejecutar análisis sobre los datos que se cargaron en BigQuery. Debes seguir las prácticas recomendadas y otorgar permisos.

¿Qué rol deberías asignarles a los analistas de negocios?

- A. `bigquery.resourceViewer` y `bigquery.dataViewer`
- B. `bigquery.user` y `bigquery.dataViewer`
- C. `bigquery.dataOwner`
- D. `storage.objectViewer` y `bigquery.user`

1.1 | Pregunta de diagnóstico 2

Cymbal Retail adquirió otra empresa en Europa. Los permisos y las políticas de acceso a los datos de esta nueva región difieren de los de la oficina central de Cymbal Retail, que se encuentra en Norteamérica. Debes definir un conjunto coherente de políticas para los proyectos de cada región, que sigan las prácticas recomendadas.


¿Qué deberías hacer?

- 
- A. Crear una organización nueva para todos los proyectos de Europa y asignar políticas a cada organización que cumplan con las leyes regionales
 - B. Implementar una jerarquía plana y asignar políticas a cada proyecto según su región
 - C. Crear carpetas de nivel superior para cada región y asignar políticas a nivel de las carpetas
 - D. Implementar políticas a nivel de los recursos que cumplan con las leyes regionales

1.1 | Pregunta de diagnóstico 3

Estás migrando datos locales a un almacén de datos en Google Cloud. Estos datos estarán disponibles para los analistas de negocios. Las reglamentaciones locales requieren que se registre información de los clientes, como números de tarjetas de crédito, números de teléfono o IDs de correo electrónico, pero que no se utilice en los análisis. Debes usar una solución confiable y recomendada para ocultar los datos sensibles.

¿Qué deberías hacer?

- 
- A. Usar la API de Cloud Data Loss Prevention (API de DLP) para identificar y ocultar datos que coincidan con los infotipos, como números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos
 - B. Borrar todas las columnas que tengan un título similar a “tarjeta de crédito”, “teléfono” y “correo electrónico”
 - C. Crear una expresión regular para identificar y borrar patrones que sean similares a números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos
 - D. Usar la API de Cloud Data Loss Prevention (API de DLP) para cambiar las fechas de las entradas que tengan números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos

1.1 | Pregunta de diagnóstico 4

Tus datos y aplicaciones residen en varias ubicaciones geográficas en Google Cloud. Algunas leyes regionales exigen que mantengas tus propias claves fuera del entorno del proveedor de servicios en la nube, mientras que otras leyes son menos restrictivas y permiten almacenar las claves con el mismo proveedor que almacena los datos. La complejidad de la administración de estas claves aumentó, por lo que necesitas una solución que pueda administrar todas tus claves de forma centralizada.

¿Qué deberías hacer?

A. Habilitar Confidential Computing para todas tus máquinas virtuales

B. Almacenar las claves en Cloud Key Management Service (Cloud KMS) y reducir la cantidad de días para la rotación de claves automática

C. Almacenar tus claves en Cloud Hardware Security Module (Cloud HSM) y recuperarlas cuando las necesites

D. Almacenar tus claves en un sistema asociado de administración de claves externas y usar Cloud External Key Manager (Cloud EKM) para obtener claves cuando sea necesario



1.1

Diseña en función de la seguridad y el cumplimiento

Cursos

[Moderniza data lakes y almacenes de datos con Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Crea un almacén de datos

[Análítica inteligente, IA y aprendizaje automático en Google Cloud](#)

- APIs de modelos de AA creadas previamente para datos no estructurados

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- IAM, cuotas y permisos
- Seguridad

[Conceptos básicos de BigQuery para profesionales de Redshift](#)

- BigQuery y Google Cloud IAM

Insignias de habilidad

[Implementa el balanceo de cargas en Compute Engine](#)

[Prepara datos para las APIs de AA en Google Cloud](#)

Documentación

[Importa datos de Google Cloud a un almacén de datos seguro de BigQuery](#)

[Referencia de roles básicos y predefinidos de IAM](#)

[Crea y administra carpetas](#)

[Jerarquía de recursos](#)

[Sensitive Data Protection](#)

[Referencia del detector de infotipos](#)

[Cloud External Key Manager](#)

[Hold your own key with Google Cloud](#)

[External Key Manager](#)

[La evolución de Cloud External Key](#)

[Manager: conoce las novedades de](#)


[Cloud EKM | Blog de Google Cloud](#)

1.2 | Pregunta de diagnóstico 5

Cymbal Retail tiene un equipo de analistas de negocios que deben corregir y mejorar un conjunto de archivos grandes de datos de entrada. Por ejemplo, se deben quitar los duplicados, las filas con errores se deben borrar y se deben agregar los datos faltantes. Estos pasos se deben implementar en todo el conjunto actual de archivos y todos los archivos que se reciban en el futuro en un proceso repetible y automatizado. Los analistas de negocios no son hábiles en programación.

¿Qué deberían hacer?

- A. Cargar los datos en Dataprep, explorarlos y editar las transformaciones, según sea necesario
- B. Crear un trabajo de Dataproc para realizar las correcciones de datos que necesites
- C. Crear una canalización de Dataflow con las correcciones de datos que necesites
- D. Cargar los datos en Hojas de cálculo de Google, explorar los datos y corregirlos, según sea necesario



1.2 | Pregunta de diagnóstico 6



Tienes una canalización de Dataflow que ejecuta trabajos de procesamiento de datos. Debes identificar las partes del código de la canalización que consumen más recursos.

- A. Usar Cloud Monitoring
- B. Usar Cloud Logging
- C. Usar Cloud Profiler
- D. Usar los Registros de auditoría de Cloud

¿Qué deberías hacer?

1.2

Diseña en función de la confiabilidad y la fidelidad

Cursos

[Crea data lakes y almacenes de datos en Google Cloud](#)

- Crea un almacén de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la compilación de canalizaciones de datos por lotes
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Supervisión
- Registros e informes de errores
- Solución de problemas y depuración
- Pruebas y CI/CD
- Confiabilidad

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Conceptos básicos de Dataprep](#)

[Lenguaje Wrangle de Dataprep](#)

[Supervisa el rendimiento de la canalización con Cloud Profiler | Cloud Dataflow](#)

1.3 | Pregunta de diagnóstico 7

Estás usando Dataproc para procesar una gran cantidad de archivos CSV. La opción de almacenamiento que elijas debe ser flexible para adaptarse a muchos nodos trabajadores en varios clústeres. Estos nodos trabajadores leerán los datos y también los escribirán para el almacenamiento intermedio entre los trabajos de procesamiento.

¿Cuál es la opción de almacenamiento recomendada en Google Cloud?

- A. Cloud SQL
- B. Discos persistentes zonales
- C. SSD local
- D. Cloud Storage



1.3 | Pregunta de diagnóstico 8

Estás administrando los datos de Cymbal Retail, que incluyen varios equipos, como venta minorista, ventas, marketing y legal. Estos equipos consumen datos de varios productores, incluidos los sistemas de punto de venta, datos de la industria, pedidos y muchos más. Actualmente, los equipos que consumen datos tienen que pedirles constantemente a los equipos que los producen que verifiquen los datos más actualizados y aclaren otras cuestiones sobre estos, como la fuente y la propiedad. Este proceso no es confiable, requiere tiempo y, a menudo, conlleva reiteradas derivaciones. Debes implementar una solución centralizada que obtenga una vista unificada de los datos de la organización y mejore la capacidad de búsqueda.

¿Qué deberías hacer?

A. Implementar una malla de datos con Dataplex y pedirles a los productores que etiqueten los datos cuando se crean

B. Implementar un data lake con Cloud Storage y crear buckets para cada equipo, como el de venta minorista, ventas y marketing

C. Implementar un almacén de datos con BigQuery y crear conjuntos de datos para cada equipo, como el de venta minorista, ventas y marketing

D. Implementar paneles en Looker que ofrecen vistas de los datos que satisfacen los requisitos de cada uno de los equipos

Google Cloud



1.3 | Diseño para la flexibilidad y la portabilidad

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
 - Cómo crear un data lake
- [Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la compilación de canalizaciones de datos por lotes

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- Portabilidad de Beam

Insignias de habilidad

[Comienza a usar Dataplex](#)

Documentación

[Prácticas recomendadas de Dataproc | Blog de Google Cloud](#)
[HDFS versus almacenamiento en la nube: ventajas, desventajas y sugerencias para la migración | Blog de Google Cloud](#)
[Descripción general de Dataplex](#)

1.4 | Pregunta de diagnóstico 9

Las leyes de la región en la que operas exigen que los archivos relacionados con todos los pedidos realizados cada día se almacenen de manera inmutable durante 365 días. La solución que recomiendas debe ser rentable.

¿Qué deberías hacer?

- 
- A. Almacenar los datos en un bucket de Cloud Storage, habilitar el control de versiones de objetos y borrar las versiones de más de 365 días
 - B. Almacenar los datos en un bucket de Cloud Storage y especificar un período de retención
 - C. Almacenar los datos en un bucket de Cloud Storage y configurar una política de ciclo de vida para borrar el archivo después de 365 días
 - D. Almacenar los datos en un bucket de Cloud Storage, habilitar el control de versiones de objetos y borrar las versiones de más de 365 días

1.4 | Pregunta de diagnóstico 10

Cymbal Retail está migrando sus centros de datos privados a Google Cloud. Durante muchos años, se acumularon cientos de terabytes de datos. Actualmente tienes una línea de 100 Mbps y debes transferir estos datos de manera confiable antes de comenzar las operaciones en Google Cloud en 45 días.

¿Qué deberías hacer?

- 
- A. Almacenar los datos en un extremo HTTPS y configurar el Servicio de transferencia de almacenamiento para copiar los datos a Cloud Storage
 - B. Subir los datos a Cloud Storage usando `gcloud storage`
 - C. Comprimir y subir los datos a los buckets de Cloud Storage con la consola de Google Cloud
 - D. Pedir una instancia de Transfer Appliance, exportar los datos en ella y enviarla a Google

1.4 | Diseño de migración de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake
- Crea un almacén de datos


[Conceptos básicos de BigQuery para profesionales de Redshift](#)

- BigQuery y Google Cloud IAM

Documentación

[Políticas de retención y bloqueos de estas políticas | Cloud Storage](#)

[Migración a Google Cloud: transfiere tus conjuntos de datos grandes](#)



Sección 2: Transferencia y procesamiento de datos

2.1 | Pregunta de diagnóstico 1



Tu equipo de ingeniería de datos recibe datos en formato JSON de fuentes externas al final de cada día. Debes diseñar la canalización de datos.

¿Qué deberías hacer?

- A. Almacenar los datos en Cloud Storage y crear una canalización de extracción, transformación y carga (ETL)
- B. Configurar tu almacén de datos de BigQuery para que sea público y pedir a las fuentes externas que inserten los datos
- C. Crear una API pública para permitir que las aplicaciones externas agreguen datos a tu almacén
- D. Almacenar los datos en discos persistentes y crear una canalización de ETL

Google Cloud

2.1 | Pregunta de diagnóstico 2



La primera etapa de tu canalización de datos procesa decenas de terabytes de datos financieros y crea un conjunto de datos disperso de series temporales como un par clave-valor.

- A. Cloud Storage
- B. Cloud SQL
- C. AlloyDB
- D. Bigtable

¿Cuál de estas opciones es un receptor de datos adecuado para la primera etapa de la canalización?

2.1 | Pregunta de diagnóstico 3



Estás procesando grandes cantidades de datos de entrada en BigQuery. Necesitas combinar estos datos con una cantidad pequeña de datos que cambian con frecuencia y que están disponibles en Cloud SQL.

¿Qué deberías hacer?

- A. Copiar los datos de Cloud SQL a una tabla nueva de BigQuery cada una hora
- B. Copiar los datos de Cloud SQL y crear una tabla combinada y normalizada cada una hora
- C. Usar una consulta federada para obtener datos de Cloud SQL
- D. Crear una canalización de Dataflow para combinar los datos de BigQuery y Cloud SQL cuando los datos de Cloud SQL cambien

2.1

Planificación de las canalizaciones de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Crea un almacén de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de BigQuery y Bigtable con alta capacidad de procesamiento

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Repaso de conceptos de Beam
- Fuentes y receptores
- Esquemas

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[¿Qué arquitectura de canalización de datos debería usar? | Blog de Google Cloud](#)

[Descripción general de Bigtable](#)

[Consultas federadas de Cloud SQL | BigQuery](#)

[Explora nuevas funciones en las consultas federadas de BigQuery | Blog de Google Cloud](#)

2.2 | Pregunta de diagnóstico 4



Tu empresa cuenta con muchos analistas de datos, pero tiene un equipo de ingeniería de datos limitado. Debes elegir una herramienta con la que los analistas puedan compilar canalizaciones de datos ellos mismos desde una interfaz gráfica de usuario.

- A. Dataflow
- B. Cloud Data Fusion
- C. Dataproc
- D. Cloud Composer

¿Cuál de estos productos representa la opción adecuada?

2.2 | Pregunta de diagnóstico 5



Administras una canalización de datos por lotes de PySpark con Dataproc. Quieres adoptar un enfoque práctico para la ejecución de la carga de trabajo, pero no quieres aprovisionar ni administrar tus propios clústeres.

¿Qué deberías hacer?

- A. Configurar el trabajo para ejecutarlo en Dataproc Serverless
- B. Configurar el trabajo para ejecutarlo con VMs Spot
- C. Volver a escribir el trabajo en Spark SQL
- D. Volver a escribir el trabajo en Dataflow con SQL

2.2 | Pregunta de diagnóstico 6



Necesitas ejecutar trabajos por lotes, lo que puede demorar muchos días en finalizar. No quieres administrar el aprovisionamiento de la infraestructura.

¿Qué deberías hacer?

- A. Usar Cloud Scheduler para ejecutar los trabajos
- B. Usar Workflows para ejecutar los trabajos
- C. Ejecutar los trabajos en Batch
- D. Usar Cloud Run para ejecutar los trabajos

2.2 | Pregunta de diagnóstico 7



Estás creando una canalización de datos de transmisión en Dataflow para los datos de los puntos de venta de Cymbal Retail. Quieres calcular la cantidad total de ventas por hora de forma continua.

¿Cuál de estas opciones de renderización en ventanas deberías usar?

- A. Ventanas de salto (llamadas ventanas deslizantes en Apache Beam)
- B. Ventanas de sesión
- C. Ventana global
- D. Ventanas de saltos de tamaño constante (llamadas ventanas fijas en Apache Beam)

2.2 | Pregunta de diagnóstico 8



Quieres compilar una canalización de análisis de datos de transmisión en Google Cloud. Debes elegir los productos adecuados para trabajar con datos de transmisión.

- A. Pub/Sub, Dataflow y BigQuery
- B. Pub/Sub, Dataprep y BigQuery
- C. Cloud Storage, Dataflow y Cloud SQL
- D. Cloud Storage, Dataprep y AlloyDB

¿Cuál de estas opciones elegirías?

2.2

Compilación de las canalizaciones

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la compilación de canalizaciones de datos por lotes
- Ejecuta Spark en Dataproc
- Serverless Data Processing with Dataflow
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub
- Funciones de transmisión de Dataflow

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- Separación de procesamiento y almacenamiento con Dataflow

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores
- Estados y temporizadores
- Dataflow SQL y DataFrames

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Rendimiento
- Pruebas y CI/CD
- Plantillas de Flex

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

Documentación

[Descripción general de Cloud Data Fusion](#)

[¿Qué es Dataproc Serverless?](#)

[Introducción a Google Batch](#)

[Comienza a usar Batch | Google Cloud](#)

[Canalizaciones de transmisión | Cloud Dataflow](#)

[Conceptos básicos del modelo de Beam](#)

[Soluciones de análisis de transmisiones | Google Cloud](#)

2.3 | Pregunta de diagnóstico 9

Tienes una canalización de datos que requiere que supervises un bucket de Cloud Storage en busca de un archivo, inicies un trabajo de Dataflow para procesar los datos de ese archivo, ejecutes una secuencia de comandos de shell para validar los datos procesados en BigQuery y, luego, borres el archivo original. Necesitas organizar esta canalización con las herramientas recomendadas.

- A. Cloud Tasks
- B. Cloud Composer
- C. Cloud Scheduler
- D. Cloud Run



¿Qué producto deberías elegir?

2.3 | Pregunta de diagnóstico 10



Estás ejecutando trabajos de Dataflow para el procesamiento de datos. Cuando los desarrolladores actualizan el código en Cloud Source Repositories, necesitas probar y, luego, implementar el código actualizado con poco esfuerzo.

- A. Terraform
- B. Compute Engine
- C. Cloud Code
- D. Cloud Build

¿Cuál de las siguientes opciones deberías usar para compilar tu canalización de integración continua y entrega continua (CI/CD) con el objetivo de procesar los datos?

2.3 Implementación y puesta en funcionamiento de las canalizaciones

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Pruebas y CI/CD

Insignias de habilidad

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)


Documentación

[Cómo usar Cloud Composer para organizar datos](#)

[Descripción general de Cloud Composer](#)

[Usa una canalización de CI/CD para tu flujo de trabajo de procesamiento de datos | Google Cloud](#)

Sección 3: Almacenamiento de los datos



3.1 | Pregunta de diagnóstico 1



Debes elegir una solución de almacenamiento de datos para admitir un sistema transaccional. Tus clientes se encuentran principalmente en una región. Quieres reducir las tareas administrativas y concentrar los esfuerzos de ingeniería en la creación de una aplicación empresarial.

- A. Usar Spanner
- B. Usar Cloud SQL
- C. Instalar una base de datos que desees en una VM de Compute Engine
- D. Crear un bucket de Cloud Storage con un bucket regional

¿Qué deberías hacer?

3.1 | Pregunta de diagnóstico 2



Debes almacenar datos por un tiempo prolongado y usarlos para crear informes trimestrales.

- A. Standard
- B. Nearline
- C. Coldline
- D. Archive

¿Qué clase de almacenamiento deberías elegir?

3.1

Selección de sistemas de almacenamiento

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Macrodatos y aprendizaje automático en Google Cloud

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Crea un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de BigQuery y Bigtable con alta capacidad de procesamiento

Documentación

[Cloud SQL para MySQL, PostgreSQL y SQL Server](#)

[¿Qué es Cloud SQL?](#)

[Clases de almacenamiento | Google Cloud](#)

3.2 | Pregunta de diagnóstico 3



Tienes varias tablas grandes en tus bases de datos transaccionales. Debes transferir todos los datos a BigQuery para que los analistas de negocios los exploren y analicen.

¿Cómo deberías diseñar el esquema en BigQuery?

- A. Conservar los datos en BigQuery con el mismo esquema que la fuente
- B. Combinar todas las tablas de bases de datos transaccionales en una sola tabla con uniones externas
- C. Rediseñar el esquema para normalizar los datos a través de la eliminación de todas las redundancias
- D. Rediseñar el esquema para desnormalizar los datos con datos anidados y repetidos

3.2 | Pregunta de diagnóstico 4



Estás transfiriendo rápidamente datos que se distribuyen en un amplio rango de fechas en BigQuery. Debes particionar la tabla para mejorar el rendimiento de las consultas.

¿Qué deberías hacer?

- A. Crear una tabla particionada por tiempo de transferencia con tipo de partición por día
- B. Crear una tabla particionada por tiempo de transferencia con tipo de partición por año
- C. Crear una tabla particionada de rango de número entero
- D. Crear una tabla particionada por columnas de unidad de tiempo con tipo de partición por año

3.2 | Pregunta de diagnóstico 5



Los analistas ejecutan de forma reiterada las mismas consultas complejas que combinan y filtran una gran cantidad de datos en BigQuery. Los datos cambian con frecuencia. Necesitas reducir el esfuerzo de los analistas.

¿Qué deberías hacer?

- A. Crear un conjunto de datos con los datos que se consultan con frecuencia
- B. Crear una vista de los datos consultados con frecuencia
- C. Exportar los datos consultados con frecuencia a una tabla nueva
- D. Exportar los datos consultados con frecuencia a Cloud SQL

3.2 | Planificación del uso de un almacén de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Crea un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Insignias de habilidad

[Crea un almacén de datos con BigQuery](#)

Documentación

[Introducción a la optimización del rendimiento de consultas | BigQuery | Google Cloud](#)

[Introducción a las tablas particionadas | BigQuery | Google Cloud](#)

[Crea tablas particionadas | BigQuery | Google Cloud](#)

[Introducción a las vistas | BigQuery | Google Cloud](#)

3.3 | Pregunta de diagnóstico 6



Tienes datos que se transfieren a diario y se analizan con frecuencia en el primer mes. Luego, los datos se conservan únicamente para las auditorías, que se realizan de manera ocasional cada cierta cantidad de años. Debes configurar un almacenamiento rentable.

¿Qué deberías hacer?

- A. Crear un bucket en Cloud Storage con el control de versiones de objetos configurado
- B. Crear un bucket en Cloud Storage con la función Autoclass configurada
- C. Configurar una política de retención de datos en Cloud Storage
- D. Configurar una política de ciclo de vida en Cloud Storage

3.3 | Pregunta de diagnóstico 7



Tienes datos almacenados en un bucket de Cloud Storage. Estás usando tanto Identity and Access Management (IAM) como Listas de control de acceso (LCA) para configurar el control de acceso.

¿Qué afirmación describe el acceso de un usuario a los objetos en el bucket?

- A. El usuario no tiene acceso si IAM rechaza el permiso.
- B. El usuario solo tiene acceso si tanto IAM como las LCA otorgan un permiso.
- C. El usuario tiene acceso si IAM o las LCA otorgan un permiso.
- D. El usuario no tiene acceso si IAM o las LCA deniegan un permiso.

3.3 | Pregunta de diagnóstico 8



Un gerente de Cymbal Retail expresa su preocupación por el acceso no autorizado a los objetos en el bucket de Cloud Storage. Debes evaluar todos los accesos a todos los objetos en el bucket.

¿Qué deberías hacer?

- A. Revisar los registros de auditoría de actividad del administrador
- B. Habilitar y, luego, revisar los registros de auditoría de acceso a los datos
- C. Enrutar los registros de actividad del administrador a un receptor de BigQuery y analizar los registros con consultas en SQL
- D. Cambiar los permisos en el bucket a solo los empleados de confianza

3.3 | Uso de un data lake

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Documentación

[Cloud Storage](#)

[Administración del ciclo de vida de los objetos | Cloud Storage](#)

[Descripción general del control de acceso | Cloud Storage](#)

[Registros de auditoría de Cloud con Cloud Storage | Google Cloud](#)

3.4 | Pregunta de diagnóstico 9



Cymbal Retail ha acumulado una gran cantidad de datos. Los analistas y los líderes tienen dificultades para comprender su significado; por ejemplo, las columnas de BigQuery. Los usuarios no saben a quiénes les pertenecen qué datos. Debes mejorar la capacidad de búsqueda de los datos.

¿Qué deberías hacer?

- A. Crear etiquetas para entradas de datos en Cloud Catalog
- B. Cambiar el nombre de las columnas de BigQuery por nombres más descriptivos
- C. Exportar los datos a Cloud Storage con nombres de archivo más descriptivos
- D. Agregar una columna de descripción correspondiente a cada columna de datos

3.4 | Pregunta de diagnóstico 10



Tienes grandes cantidades de datos almacenados en Cloud Storage y BigQuery. Algunos están procesados, pero otros todavía no lo están. Tienes una malla de datos que se creó en Dataplex. Debes facilitar el proceso de descubrimiento y uso de los datos a los usuarios internos.

¿Qué deberías hacer?

- A. Crear un lake para los datos de Cloud Storage y una zona para los datos de BigQuery
- B. Crear un lake para los datos de BigQuery y una zona para los datos de Cloud Storage
- C. Crear un lake para los datos sin procesar y recursos para los datos procesados
- D. Crear una zona de datos sin procesar para los datos no procesados y una zona de datos seleccionados para los datos procesados.

3.4 | Diseño de una malla de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la compilación de canalizaciones de datos por lotes

Insignias de habilidad

[Conceptos básicos de Data Catalog](#)

[Comienza a usar Dataplex](#)


Documentación

[Etiquetas y plantillas de etiquetas | Documentación de Data Catalog | Google Cloud](#)

[Guía de inicio rápido: Etiqueta una tabla de BigQuery con Data Catalog](#)

[Descripción general de Dataplex | Google Cloud](#)

Sección 4: Prepara los datos y úsalos para análisis



4.1 | Pregunta de diagnóstico 1



En tu empresa se usa Google Workspace, y los miembros del equipo de liderazgo están familiarizados con sus apps empresariales y herramientas de colaboración. Quieren una solución rentable que utilice sus conocimientos existentes para evaluar, analizar, filtrar y visualizar datos almacenados en BigQuery.

¿Cuál de estas opciones debes elegir para crear una solución para el equipo de liderazgo?

- A. Crear modelos en Looker
- B. Configurar Hojas conectadas
- C. Configurar Tableau
- D. Configurar Looker Studio

4.1 | Pregunta de diagnóstico 2



Tienes datos en PostgreSQL, que se diseñó para disminuir la redundancia. Quieres transferir los datos a BigQuery para realizar análisis. Los datos de origen son jerárquicos y se consultan en conjunto con frecuencia. Necesitas diseñar un esquema de BigQuery de alto rendimiento.

- A. Usar campos anidados y repetidos
- B. Conservar los datos siempre en un formato normalizado
- C. Copiar las tablas principales y usar consultas federadas para las tablas secundarias
- D. Copiar los datos normalizados en particiones

¿Qué deberías hacer?

4.1 | Pregunta de diagnóstico 3



Ejecutas repetidamente las mismas consultas uniendo varias tablas. Las tablas originales se modifican unas diez veces al día. Quieres un enfoque de consultas optimizado.

- A. Vistas
- B. Vistas materializadas
- C. Consultas federadas
- D. Particiones

¿Qué función deberías usar?

4.1 | Pregunta de diagnóstico 4



Tienes datos de estadísticas almacenados en BigQuery. Necesitas una manera eficiente de procesar valores en un grupo de filas y que se devuelva un solo resultado para cada fila.

- A. Usar una función de agregación
- B. Usar una UDF (función definida por el usuario)
- C. Usar BigQuery ML
- D. Usar una función analítica con una cláusula OVER

¿Qué deberías hacer?

4.1 | Pregunta de diagnóstico 5



Necesitas optimizar el rendimiento de las consultas en BigQuery. Tus tablas no están particionadas ni agrupadas en clústeres.

¿Qué técnica de optimización puedes usar?

- A. Cargar tus inserciones y actualizaciones por lotes
- B. Usar la cláusula LIMIT para reducir la cantidad de datos leídos
- C. Filtrar los datos lo más tarde posible
- D. Realizar uniones de tablas consigo mismas en los datos

4.1

Preparación de los datos para su visualización

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Ingeniería de datos para la transmisión de datos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Crea un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de Dataflow

- Funcionalidad y rendimiento avanzados de BigQuery

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Introducción a las herramientas de análisis y de inteligencia empresarial](#)

[Usa campos anidados y repetidos](#)

[Introducción a las vistas materializadas](#)

[Llamadas a la función analítica](#)

[Optimiza el procesamiento de las consultas](#)

[Optimiza el procesamiento de las consultas](#)

4.2 | Pregunta de diagnóstico 6



Tus datos en BigQuery tienen algunas columnas que son sumamente sensibles. Necesitas permitir que solo usuarios determinados vean ciertas columnas.

¿Qué deberías hacer?

- A. Crear un conjunto de datos nuevo con los datos de la columna
- B. Crear una tabla nueva con los datos de la columna
- C. Usar etiquetas de política
- D. Usar permisos de Identity and Access Management (IAM)

4.2 | Pregunta de diagnóstico 7



A lo largo de varios años, en tu empresa han recopilado datos relevantes para la industria. Los datos procesados son útiles para tus socios, quienes están dispuestos a pagar por usarlos. Debes asegurarte de implementar el control de acceso adecuado sobre los datos.

- A. Exportar los datos a archivos ZIP y compartirlos a través de Cloud Storage
- B. Alojarse los datos en Analytics Hub
- C. Exportar los datos a discos persistentes y compartirlos a través de un extremo de FTP
- D. Alojarse los datos en Cloud SQL

¿Qué deberías hacer?

4.2 | Pregunta de diagnóstico 8



Tienes un conjunto complejo de datos que provienen de múltiples fuentes. Los analistas de tu equipo necesitan estudiar los datos, visualizarlos y publicar informes para las partes interesadas internas y externas. Debes facilitarles a los analistas trabajar con los datos abstrayendo las múltiples fuentes de datos.

- A. Looker Studio
- B. Hojas conectadas
- C. Biblioteca D3.js
- D. Looker

¿Qué herramientas recomendarías?

4.2 | Uso compartido de datos

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Ingeniería de datos para la transmisión de datos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la compilación de canalizaciones de datos por lotes

Insignias de habilidad

[Conceptos básicos de Data Catalog](#)

Documentación

[Introducción al control de acceso a nivel de columna](#)

[Analytics Hub | Intercambio y uso compartido de datos | Google Cloud](#)

[Introducción a Analytics Hub | BigQuery](#)

[Protege los intercambios de datos y el uso compartido de datos con Analytics Hub](#)

[Looker, plataforma de inteligencia empresarial y análisis incorporados](#)

4.3 | Pregunta de diagnóstico 9



Creaste modelos de aprendizaje automático (AA) basados en tus datos. En la etapa de producción, los modelos de AA no están dando resultados satisfactorios. Cuando examinas los datos, te parece que no representan lo suficiente los objetivos comerciales. Debes crear un modelo de aprendizaje automático más preciso.

¿Qué deberías hacer?

- A. Entrenar el modelo con más datos similares
- B. Llevar a cabo la regularización L2
- C. Llevar a cabo la ingeniería de atributos y usar los conocimientos sobre el dominio para mejorar los datos de las columnas
- D. Entrenar el modelo con los mismos datos, pero usando más ciclos de entrenamiento

4.3 | Pregunta de diagnóstico 10



Usaste Dataplex para crear lakes y zonas para tus datos empresariales. Sin embargo, algunos archivos no se descubren.

¿Cuál podría ser el problema?

- A. Tienes un patrón de exclusión que coincide con los archivos.
- B. Programaste el descubrimiento para que se ejecute cada hora.
- C. Los archivos están en formato ORC.
- D. Los archivos están en formato Parquet.

4.3 Exploración y análisis de datos

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Macrodatos con BigQuery
- Flujo de trabajo del aprendizaje automático con Vertex AI

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la compilación de canalizaciones de datos por lotes

[Analítica inteligente, IA y aprendizaje automático en Google Cloud](#)

- Creación de modelos personalizados con SQL en BigQuery ML

Insignias de habilidad


[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Realizar ingeniería de atributos con la cláusula TRANSFORM | BigQuery ML | Google Cloud](#)

[Descripción general del procesamiento previo de atributos | BigQuery | Google Cloud](#)

[Descubrimiento de datos | Dataplex | Google Cloud](#)



Sección 5: Mantenimiento y automatización de las cargas de trabajo de datos

5.1 | Pregunta de diagnóstico 1



Necesitas diseñar un clúster de Dataproc para ejecutar varios trabajos pequeños. Muchos trabajos son de prioridad alta, pero no todos.

¿Qué deberías hacer?

- A. Volver a usar el mismo clúster y ejecutar cada trabajo en secuencia
- B. Volver a usar el mismo clúster para ejecutar todos los trabajos en paralelo
- C. Usar clústeres efímeros
- D. Usar el ajuste de escala automático de clústeres

5.1 | Optimización de recursos

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

Documentación

[Dataproc Job Optimization](#)

[How-to Guide | Google Cloud](#)

[Blog](#)

5.2 | Pregunta de diagnóstico 2



Tienes que crear tareas repetitivas de procesamiento de datos a través de Cloud Composer. Debes seguir las prácticas recomendadas y los enfoques recomendados.

¿Qué deberías hacer?

- A. Definir cada tarea como responsable de una operación
- B. Usar la hora actual con la función `now()` para el procesamiento
- C. Actualizar los datos con las sentencias `INSERT` durante la ejecución de la tarea
- D. Combinar varias funcionalidades en una sola ejecución de tarea

5.2

Diseño de automatización y repetibilidad

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

Insignias de habilidad

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Escribe DAG de Airflow | Cloud Composer](#)

[DAGs — Airflow Documentation](#)

[Prácticas recomendadas para escribir DAG en Apache Airflow | Documentación de Astronomer](#)

5.3 | Pregunta de diagnóstico 3



Varios analistas deben preparar informes los lunes por la mañana, por lo que BigQuery se utiliza mucho. Quieres adoptar un enfoque rentable para administrar esta demanda.

¿Qué deberías hacer?

- A. Usar precios según demanda
- B. Usar ranuras flexibles
- C. Usar la edición Enterprise de BigQuery con un compromiso por un año
- D. Usar la edición Enterprise Plus de BigQuery con un compromiso por tres años

5.3 | Pregunta de diagnóstico 4



Tienes un equipo de analistas de datos que ejecutan consultas de manera interactiva en BigQuery durante el horario laboral. También tienes miles de consultas de generación de informes que se ejecutan de manera simultánea. A menudo aparece un error: *Se excedieron los límites de frecuencia: muchas consultas simultáneas para este project_and_region*.

- A. Ejecutar todas las consultas en modo interactivo
- B. Crear una reserva anual de ranuras de BigQuery
- C. Ejecutar las consultas de generación de informes en el modo por lotes
- D. Crear una vista para ejecutar las consultas

¿Cómo resolverías el problema?

5.3 | Organización de las cargas de trabajo según los requisitos empresariales

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Crea un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Documentación

[Scale cloud data warehouse up and down quickly](#)

[Introducción a las reservas | BigQuery | Google Cloud](#)

[Introducción a las ediciones de BigQuery | Google Cloud](#)

[Ejecuta una consulta | BigQuery | Google Cloud](#)

[Soluciona problemas de cuota y de límite | BigQuery | Google Cloud](#)

5.4 | Pregunta de diagnóstico 5

Tienes una canalización de Dataflow en producción. Para determinados datos, el sistema parece atascarse más de lo habitual, lo que provoca retrasos en la ejecución de la canalización. Quieres hacer seguimiento de dichos problemas y resolverlos de manera confiable y proactiva.

¿Qué deberías hacer?

- A. Revisar los registros de Dataflow con regularidad
- B. Configurar alertas con el código de Cloud Run Functions que revisa los registros de auditoría con regularidad
- C. Revisar el panel de Cloud Monitoring con regularidad
- D. Configurar alertas en Cloud Monitoring según el retraso del sistema



5.4 | Pregunta de diagnóstico 6



Cuando ejecutas trabajos de Dataflow, ves este error en los registros: *"Se detectó la tecla de acceso rápido HOT_KEY_NAME en..."*. Necesitas resolver este problema y mejorar el rendimiento de la carga de trabajo.

¿Qué deberías hacer?

- A. Inhabilitar Dataflow Shuffle
- B. Aumentar los datos con la tecla de acceso rápido
- C. Garantizar que los datos estén distribuidos de manera uniforme
- D. Agregar más instancias de procesamiento para procesar

5.4 | Pregunta de diagnóstico 7



Un colega de Cymbal Retail te pregunta sobre la configuración del ajuste de escala automático de Dataproc para un proyecto.

¿En qué situación Google recomienda la habilitación del ajuste de escala automático?

- A. Cuando deseas escalar el sistema de archivos distribuidos de Hadoop (HDFS) en el clúster.
- B. Cuando deseas escalar horizontalmente clústeres de un solo trabajo.
- C. Cuando deseas reducir la escala verticalmente de los clústeres inactivos al tamaño mínimo.
- D. Cuando hay cargas de trabajo de diferente tamaño en el clúster.

5.4 Procesos de supervisión y solución de problemas

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub
- Funcionalidad y rendimiento avanzados de BigQuery

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- IAM, cuotas y permisos

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Estado y temporizadores
- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Supervisión
- Solución de problemas y depuración
- Confiabilidad

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

Documentación

[Usa Cloud Monitoring para las canalizaciones de Dataflow](#)

[Soluciona errores de Dataflow | Google Cloud](#)

[Soluciona problemas de demora en trabajos por lotes | Cloud Dataflow](#)

[Ajuste de escala automático de clústeres | Documentación de Dataproc | Google Cloud](#)

5.5 | Pregunta de diagnóstico 8



Cymbal Retail procesa datos de transmisión en Dataflow con Pub/Sub como fuente. Necesitas planificar la recuperación ante desastres y brindar protección contra fallas zonales.

- A. Crear instantáneas de Dataflow de forma periódica
- B. Crear trabajos de Dataflow a partir de plantillas
- C. Habilitar el ajuste de escala automático vertical
- D. Habilitar Dataflow Shuffle

¿Qué deberías hacer?

5.5 | Pregunta de diagnóstico 9



Ejecutas una instancia de Cloud SQL de una empresa que requiere que la base de datos sea accesible para realizar transacciones. Necesitas garantizar que el tiempo de inactividad sea mínimo para las transacciones de la base de datos.

- A. Configurar la replicación
- B. Configurar la alta disponibilidad
- C. Configurar las copias de seguridad
- D. Configurar las copias de seguridad y aumentar la cantidad de copias de seguridad

¿Qué deberías hacer?

5.5 | Pregunta de diagnóstico 10



Estás ejecutando una canalización de Dataflow en producción. En ocasiones, los datos de entrada para esta canalización son incoherentes. Además de procesar los datos válidos, deseas capturar de forma eficaz los datos de entrada erróneos para su análisis.

¿Qué deberías hacer?

- A. Volver a leer los datos de entrada y crear salidas independientes para los datos válidos y erróneos
- B. Leer los datos una vez y dividirlos en dos canalizaciones, una para generar datos válidos y otra para generar datos erróneos
- C. Verificar la existencia de datos erróneos en los registros
- D. Crear una salida complementaria para los datos erróneos

5.5 Reconocimiento de las fallas y mitigación del impacto

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Estado y temporizadores
- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Solución de problemas y depuración
- Confiabilidad

Documentación

[Usa instantáneas de Dataflow | Google Cloud](#)

[Acerca de la alta disponibilidad | Cloud SQL para MySQL](#)

[Diseña tu canalización](#)



Reserva tiempo para prepararte



¿Cuándo realizarás el examen?

¿Cuántas semanas tienes para prepararte?

¿Cuántas horas a la semana destinarás a prepararte para el examen?

¿Cuántas horas de preparación tendrás en total?

Plan de estudios semanal

Ahora, considera lo que descubriste sobre tus conocimientos y habilidades a través de las preguntas de diagnóstico de este curso. Deberías tener mayor claridad en cuanto a las áreas en las que debes enfocarte y los recursos que tienes disponibles.

Utiliza la siguiente plantilla para planificar tus objetivos de estudio semanales. Considera:

- ¿En qué temas o secciones de la guía te enfocarás?
- ¿Qué cursos (o módulos específicos) te ayudarán a aprender más?
- ¿En qué insignias de habilidad o labs trabajarás para obtener experiencia práctica?
- ¿Qué vínculos de documentación consultarás?
- ¿Qué recursos adicionales usarás (por ejemplo, modelos de preguntas)?
- ¿Qué harás para prepararte para los casos de éxito?

Puedes hacer algunas de estas actividades cada semana, o todas ellas.

Duplica la plantilla semanal según la cantidad de semanas en tu recorrido de preparación individual.



Plantilla de estudio semanal (ejemplo)

Áreas de interés:

Uso de BigQuery como un almacén de datos

Cursos o módulos
que se completarán:

[Moderniza data lakes y almacenes de datos con Google Cloud](#)

- Crea un almacén de datos

Insignias de habilidad
o labs que se
completarán:

[Crea un almacén de datos con BigQuery](#)

Documentación
que se revisará:

[Descripción general del almacenamiento de BigQuery | Google Cloud](#)

[Descripción general de los análisis de BigQuery | Google Cloud](#)

[Introducción a la administración de BigQuery | Google Cloud](#)

[Organiza los recursos de BigQuery | Google Cloud](#)

Recursos de estudio
adicionales:

Preguntas de ejemplo 1-5

Plantilla de estudio semanal

Áreas de interés:

Cursos o módulos
que se completarán:

Insignias de habilidad
o labs que se
completarán:

Documentación
que se revisará:

Recursos de estudio
adicionales: