





Cómo prepararte para convertirte en Professional Data Engineer

Módulo 1: Diseño de sistemas de procesamiento de datos

Te damos la bienvenida al Módulo 1: Diseño de sistemas de procesamiento de datos

Revisión y plan de estudios




Google Cloud

Revisemos cómo usar estas preguntas de diagnóstico para identificar qué incluir en tu plan de estudios.

Recuerda que este curso no está diseñado para enseñarte todo lo que necesitas saber para el examen y que las preguntas de diagnóstico no incluyen todo lo que podría preguntarse en el examen. En su lugar, esta actividad se diseñó para ayudarte a comprender mejor el contenido de la sección y las diferentes habilidades que debes desarrollar en tu preparación para la certificación.

Plan de estudios:

Diseño de sistemas de procesamiento de datos



- 1.1 Diseño para la seguridad y el cumplimiento
- 1.2 Diseño para la confiabilidad y la fidelidad
- 1.3 Diseño para la flexibilidad y la portabilidad
- 1.4 Diseño de migraciones de datos

Google Cloud

En la revisión, verás los objetivos de esta sección del examen y las preguntas que acabas de responder sobre cada uno de ellos. Presentaremos un objetivo, revisaremos brevemente las respuestas a las preguntas relacionadas y explicaremos dónde puedes encontrar más información en los recursos de aprendizaje o en la documentación de Google. A medida que revises el objetivo de cada sección, usa la página de tu cuaderno de ejercicios para marcar la documentación, los cursos y las insignias de habilidad en particular que quieras destacar en tu plan de estudios.

1.1 | Diseño para la seguridad y el cumplimiento

Comprende las siguientes consideraciones:

- Identity and Access Management (p. ej., IAM y políticas de la organización)
- Seguridad de los datos (administración de claves y encriptación)
- Privacidad (p. ej., información de identificación personal y la API de Cloud Data Loss Prevention)
- Consideraciones regionales (soberanía de los datos) para el acceso y el almacenamiento de datos
- Cumplimiento de leyes y reglamentaciones

Google Cloud

Acabas de revisar preguntas de diagnóstico que abordaban diferentes aspectos del diseño de migraciones de datos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen

1.1 | Análisis de la pregunta de diagnóstico 1



Los analistas de negocios de tu equipo tienen que ejecutar análisis sobre los datos que se cargaron en BigQuery. Debes seguir las prácticas recomendadas y otorgar permisos.

¿Qué rol deberías asignarles a los analistas de negocios?

- A. `bigquery.resourceViewer` y `bigquery.dataViewer`
- B. `bigquery.user` y `bigquery.dataViewer`
- C. `bigquery.dataOwner`
- D. `storage.objectViewer` y `bigquery.user`

Google Cloud

Comentarios:

- A. Incorrecto. El rol `resourceViewer` otorga permisos para ver la capacidad y las reservas, lo que no es suficiente para ejecutar análisis.
- B. Correcto. Los analistas tienen que ver los datos y ejecutar consultas en ellos, lo que es posible con estos roles predefinidos.
- C. Incorrecto. El rol `dataOwner` tiene más permisos de los que necesitan los analistas de negocios.
- D. Incorrecto. El rol `storage.objectViewer` es útil cuando se tienen que ejecutar consultas federadas con Cloud Storage, pero no lo es en este caso de uso. Los analistas de negocios también necesitarán permisos incluidos en el rol `bigquery.dataViewer`.

Vínculos:

https://cloud.google.com/architecture/help-secure-the-pipeline-from-your-data-lake-to-your-data-warehouse#business_analyst

<https://cloud.google.com/iam/docs/understanding-roles#bigquery-roles>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake
- Cómo crear un almacén de datos

[Analítica inteligente. IA y aprendizaje automático en Google Cloud](#)

- APIs de modelos de AA creadas previamente para datos no estructurados

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- IAM, cuotas y permisos
- Seguridad

Insignias de habilidad:

[Implementa el balanceo de cargas en Compute Engine](#)

[Prepara datos para las APIs de AA en Google Cloud](#)

Resumen:

El principio de privilegio mínimo determina que no se deben otorgar más permisos de los necesarios para el trabajo. Por ello, es importante entender el alcance del rol y cómo se relaciona con los roles de Identity and Access Management (IAM). Lo ideal es que elijas los roles predefinidos, pero, si no ofrecen el conjunto de permisos necesarios, crea un rol personalizado.

1.1 | Análisis de la pregunta de diagnóstico 2



Cymbal Retail adquirió otra empresa en Europa. Los permisos y las políticas de acceso a los datos de esta nueva región difieren de los de la oficina central de Cymbal Retail, que se encuentra en Norteamérica. Debes definir un conjunto coherente de políticas para los proyectos de cada región, que sigan las prácticas recomendadas.

¿Qué deberías hacer?

- A. Crear una organización nueva para todos los proyectos de Europa y asignar políticas a cada organización que cumplan con las leyes regionales
- B. Implementar una jerarquía plana y asignar políticas a cada proyecto según su región
- C. Crear carpetas de nivel superior para cada región y asignar políticas a nivel de las carpetas
- D. Implementar políticas a nivel de los recursos que cumplan con las leyes regionales

Google Cloud

Comentarios:

- A. Incorrecto. Crear una nueva organización para aplicar otras políticas o trabajar con una región diferente no es una práctica recomendada. Este requisito se puede administrar dentro de la misma organización usando carpetas.
- B. Incorrecto. No se recomienda implementar una jerarquía plana porque la configuración de la política se debe aplicar de manera individual en cada proyecto.
- C. Correcto. Las carpetas agrupan los proyectos relacionados de una organización. También se pueden usar para aplicar políticas coherentes para los proyectos de la carpeta.
- D. Incorrecto. Aplicar políticas a nivel de los recursos requiere mucho tiempo y puede resultar incoherente.

Vínculos:

<https://cloud.google.com/resource-manager/docs/creating-managing-folders>

<https://cloud.google.com/resource-manager/docs/cloud-platform-resource-hierarchy>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake
- Cómo crear un almacén de datos

Conceptos básicos de BigQuery para profesionales de Redshift

- BigQuery y Google Cloud IAM

Resumen:

La jerarquía de recursos de Google Cloud, el control de acceso y las políticas de la organización te permiten ajustar la configuración de Identity and Access Management (IAM) a un nivel superior en la jerarquía que heredarán los recursos secundarios. Agrupar los recursos en carpetas también te permite contar con políticas coherentes para todos los proyectos y los recursos que contienen.

1.1 | Análisis de la pregunta de diagnóstico 3



Estás migrando datos locales a un almacén de datos en Google Cloud. Estos datos estarán disponibles para los analistas de negocios. Las reglamentaciones locales requieren que determinada información de los clientes (como los números de tarjetas de crédito, los números de teléfono o los IDs de correo electrónico) se registre, pero no se utilice en los análisis. Debes usar una solución confiable y recomendada para ocultar los datos sensibles.

¿Qué deberías hacer?

- A. Usar la API de Cloud Data Loss Prevention (API de DLP) para identificar y ocultar datos que coincidan con los infotipos, como números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos
- B. Borrar todas las columnas que tengan un título similar a "tarjeta de crédito", "teléfono" y "correo electrónico"
- C. Crear una expresión regular para identificar y borrar patrones que sean similares a números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos
- D. Usar la API de Cloud Data Loss Prevention (API de DLP) para cambiar las fechas de las entradas que tengan números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos

Google Cloud

Comentarios:

- A. Correcto. La API de Cloud Data Loss Prevention, que forma parte de Sensitive Data Protection, te ayuda a descubrir, clasificar y proteger tus datos más sensibles. Hay infotipos predefinidos que puedes usar para identificar y ocultar tipos de datos específicos.
- B. Incorrecto. Borrar columnas según el título no es una forma confiable de proteger datos sensibles porque es posible que las columnas contengan estos datos incluso si el título no lo indica. Por ejemplo, podría haber una columna de comentarios con información privada sensible.
- C. Incorrecto. Determinar las expresiones regulares que coincidan con los diferentes tipos de datos puede ser más tedioso y menos preciso que usar Sensitive Data Protection.
- D. Cambiar las fechas de las entradas no oculta la información de identificación personal (PII), como números de tarjetas de crédito, números de teléfono o IDs de correos electrónicos.

Vínculos:

<https://cloud.google.com/security/products/sensitive-data-protection>

<https://cloud.google.com/sensitive-data-protection/docs/infotypes-reference>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

Conceptos básicos de BigQuery para profesionales de Redshift

- BigQuery y Google Cloud IAM

Resumen:

A menudo, las reglamentaciones exigen que registres diferentes tipos de datos, pero otras establecen requisitos estrictos sobre la forma en que manejas y usas los datos. Por lo general, no se permite compartir ni usar información de identificación personal (PII). Sensitive Data Protection cuenta con más de 150 infotipos que pueden detectar diversos tipos de datos. Según tus necesidades comerciales, puedes tomar diferentes medidas, como ocultar o enmascarar datos sensibles, para cumplir con las reglamentaciones.

1.1 | Análisis de la pregunta de diagnóstico 4



Tus datos y aplicaciones residen en varias ubicaciones geográficas en Google Cloud. Algunas leyes regionales exigen que mantengas tus propias claves fuera del entorno del proveedor de servicios en la nube, mientras que otras leyes son menos restrictivas y permiten almacenar las claves con el mismo proveedor que almacena los datos. La complejidad de la administración de estas claves aumentó, por lo que necesitas una solución que pueda administrar todas tus claves de forma centralizada.

¿Qué deberías hacer?

- A. Habilitar Confidential Computing para todas tus máquinas virtuales
- B. Almacenar las claves en Cloud Key Management Service (Cloud KMS) y reducir la cantidad de días para la rotación de claves automática
- C. Almacenar tus claves en Cloud Hardware Security Module (Cloud HSM) y recuperarlas cuando las necesites
- D. Almacenar tus claves en un sistema asociado de administración de claves externas y usar Cloud External Key Manager (Cloud EKM) para obtener claves cuando sea necesario

Google Cloud

Comentarios:

- A. Incorrecto. Confidential Computing no influye en el almacenamiento de los datos.
- B. Incorrecto. Cloud KMS almacena claves en Google Cloud; por lo que no se satisface el requisito de que los datos y las claves se almacenen en entornos de diferentes proveedores.
- C. Incorrecto. Cloud HSM es un servicio de Google Cloud que almacena claves en módulos de seguridad de hardware en Google Cloud, lo que no satisface el requisito de que los datos y las claves se almacenen en entornos de diferentes proveedores.
- D. Correcto. Con Cloud EKM, administras el acceso a tus claves administradas, que residen fuera de Google Cloud, de forma externa. Dado que necesitas una única solución que también almacene claves de forma externa, esta sería la opción adecuada.

Vínculos:

Cloud KMS - <https://cloud.google.com/kms/docs/key-management-service>

Cloud HSM - <https://cloud.google.com/kms/docs/hsm>

Cloud EKM - <https://cloud.google.com/kms/docs/ekm>

Más información:

Lab:

[Cómo comenzar a usar Cloud KMS](#)

Resumen:

Google Cloud ofrece diversas opciones para almacenar claves seguras que permitan un acceso controlado a los activos. Estas opciones van desde almacenar claves directamente en la nube con Cloud KMS, en módulos de seguridad de hardware mediante Cloud HSM, y fuera de Google Cloud como claves administradas externamente (Cloud EKM).

1.1

Diseño para la seguridad y el cumplimiento

Cursos

[Moderniza data lakes y almacenes de datos con Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Cómo crear un almacén de datos

[Análítica inteligente, IA y aprendizaje automático en Google Cloud](#)

- APIs de modelos de AA creadas previamente para datos no estructurados

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- IAM, cuotas y permisos
- Seguridad

[Conceptos básicos de BigQuery para profesionales de Redshift](#)

- BigQuery y Google Cloud IAM

Insignias de habilidad

[Implementa el balanceo de cargas en Compute Engine](#)

[Prepara datos para las APIs de AA en Google Cloud](#)

Documentación

[Importa datos de Google Cloud a un almacén de datos seguro de BigQuery](#)

[Referencia de roles básicos y predefinidos de IAM](#)

[Crea y administra carpetas](#)

[Jerarquía de recursos](#)

[Sensitive Data Protection](#)

[Referencia del detector de infotipos](#)

[Cloud External Key Manager](#)

[Conserva tus propias claves con Cloud](#)

[External Key Manager de Google](#)

[La evolución de Cloud External Key](#)

[Manager: conoce las novedades de Cloud EKM | Blog de Google Cloud](#)

Analizaste algunas preguntas de diagnóstico que abordaron distintos aspectos del diseño de sistemas de procesamiento de datos para la seguridad y el cumplimiento. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

https://cloud.google.com/architecture/confidential-data-warehouse-blueprint#business_analyst

<https://cloud.google.com/iam/docs/understanding-roles#bigquery-roles>

<https://cloud.google.com/resource-manager/docs/creating-managing-folders>

<https://cloud.google.com/resource-manager/docs/cloud-platform-resource-hierarchy>

<https://cloud.google.com/security/products/sensitive-data-protection>

<https://cloud.google.com/sensitive-data-protection/docs/infotypes-reference>

<https://cloud.google.com/kms/docs/ekm>

<https://cloud.google.com/blog/products/identity-security/hold-your-own-key-with-google-cloud-external-key-manager>

<https://cloud.google.com/blog/products/identity-security/whats-new-with-cloud-ekm>

1.2 | Diseño para la confiabilidad y la fidelidad

Comprende las siguientes consideraciones:

- Preparación y limpieza de los datos (p. ej., Dataprep, Dataflow y Cloud Data Fusion)
- Supervisión y organización de canalizaciones de datos
- Recuperación ante desastres y tolerancia a errores
- Toma de decisiones relacionadas con el cumplimiento y la disponibilidad de ACID (atomicidad, coherencia, aislamiento y durabilidad)
- Validación de datos

Google Cloud

Las actividades de limpieza de datos y transformación de datos son una de las preocupaciones principales de un Professional Data Engineer. Google Cloud ofrece varias herramientas, como Dataflow, Cloud Data Fusion, Dataprep, etc., para realizar la limpieza y la transformación de datos. Como Professional Data Engineer, deberías poder seleccionar la herramienta más apropiada según el caso de uso. A menudo, un Professional Data Engineer crea canalizaciones de datos complejas para que la actividad de procesamiento de datos se pueda automatizar en su totalidad. Una vez que se hayan completado los pasos de limpieza y transformación de datos, los datos de salida se deben almacenar en una base de datos adecuada. Un Professional Data Engineer debe elegir según el tipo de datos, es decir, si son estructurados o no estructurados, si son para un caso de uso analítico o un caso de uso transaccional, entre otros.

En la pregunta 5, se te consultó sobre las estrategias y las opciones para la preparación de los datos y el control de calidad. En la pregunta 6, se te interrogó sobre las estrategias y opciones para supervisar y asegurar la confiabilidad de las canalizaciones de datos.

1.2 | Análisis de la pregunta de diagnóstico 5



Cymbal Retail tiene un equipo de analistas de negocios que deben corregir y mejorar un conjunto de archivos grandes de datos de entrada. Por ejemplo, se deben quitar los duplicados, las filas con errores se deben borrar y se deben agregar los datos faltantes. Estos pasos se deben implementar en todo el conjunto actual de archivos y todos los archivos que se reciban en el futuro en un proceso repetible y automatizado. Los analistas de negocios no son hábiles en programación.

¿Qué deberían hacer?

- A. Cargar los datos en Dataprep, explorarlos y editar las transformaciones, según sea necesario
- B. Crear un trabajo de Dataproc para realizar las correcciones de datos que necesites
- C. Crear una canalización de Dataflow con las correcciones de datos que necesites
- D. Cargar los datos en Hojas de cálculo de Google, explorar los datos y corregirlos, según sea necesario

Google Cloud

Comentarios:

- A. Correcto. Dataprep permite cargar grandes cantidades de datos y corregirlos a nivel visual, lo que sería muy práctico para quienes no tienen conocimientos de programación. Los pasos de tratamiento de datos se pueden registrar como una serie de transformaciones que se pueden volver a aplicar en el futuro a otros datos.
- B. Incorrecto. Dataproc requiere conocimientos de programación y no ofrece una interfaz visual de tratamiento de datos, que es lo que necesita este equipo.
- C. Incorrecto. Dataflow requiere que escribas código nuevo, lo cual no es posible para los analistas de datos.
- D. Incorrecto. Realizar el tratamiento de datos en Hojas de cálculo de Google no es un proceso automatizable en la canalización de datos; por lo tanto, no es eficaz con respecto a este requisito.

Vínculos:

<https://help.alteryx.com/dataprep/en/trifacta-application/basics.html>

<https://help.alteryx.com/dataprep/en/trifacta-application/wrangle-language.html>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Solución de problemas y depuración

Insignias de habilidad:

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

Dataprep ofrece una interfaz visual para transformar datos. Los datos se pueden visualizar como una tabla con filas y columnas. Luego, el usuario puede editar los datos, que después se capturan y se vuelven a ejecutar en otros conjuntos de datos.

1.2 | Análisis de la pregunta de diagnóstico 6



Estás ejecutando una canalización de firma de método DoFn proporcionada por el usuario en Dataflow, y tú definiste la función. El código se ejecuta lentamente y deseas examinar más a fondo el código de la canalización para comprender mejor el motivo.

- A. Usar Cloud Monitoring
- B. Usar Cloud Logging
- C. Usar Cloud Profiler
- D. Usar Registros de auditoría de Cloud

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Cloud Monitoring ofrece diagnósticos útiles sobre trabajos de Dataflow, pero este requisito requiere las funciones de Cloud Profiler.
- B. Incorrecto. Los resultados que captura Cloud Logging no son suficientes por sí mismos para determinar el uso de los recursos.
- C. Correcto. Cloud Profiler muestra un gráfico tipo llama de las estadísticas de los trabajos en ejecución, que se puede usar para evaluar el uso de los recursos.
- D. Incorrecto. Los Registros de auditoría de Cloud capturan los eventos administrativos. No ofrecen datos suficientes para determinar el uso de los recursos de Dataflow.

Vínculos:

<https://cloud.google.com/dataflow/docs/guides/profiling-a-pipeline>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

Crea sistemas resilientes de análisis de transmisiones en Google Cloud

- Mensajería sin servidores con Pub/Sub

Procesamiento de datos sin servidores con Dataflow: Operaciones

- Supervisión
- Registros e informes de errores
- Solución de problemas y depuración
- Pruebas y CI/CD
- Confiabilidad

Resumen:

Google Cloud tiene varias herramientas para supervisar y evaluar los recursos y ejecutar cargas de trabajo. Están bien integradas en muchos productos. Habilita las herramientas y revisa los datos para identificar cuellos de botella o errores en tus canalizaciones de datos.

1.2

Diseño para la confiabilidad y la fidelidad

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Supervisión
- Registros e informes de errores
- Solución de problemas y depuración
- Pruebas y CI/CD
- Confiabilidad

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Conceptos básicos de Dataprep](#)

[Lenguaje Wrangle de Dataprep](#)

[Supervisa el rendimiento de la canalización con Cloud Profiler | Cloud Dataflow](#)

Las preguntas de diagnóstico que acabamos de revisar abordaron algunos aspectos del diseño para la confiabilidad y la fidelidad. Estos son algunos cursos y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://help.alteryx.com/dataprep/en/trifacta-application/basics.html>

<https://help.alteryx.com/dataprep/en/trifacta-application/wrangle-language.html>

<https://cloud.google.com/dataflow/docs/guides/profiling-a-pipeline>

1.3 | Diseño para la flexibilidad y la portabilidad

Comprende las siguientes consideraciones:

- Asignación de los requisitos comerciales actuales y futuros a la arquitectura
- Diseño de la portabilidad de aplicaciones y datos (p. ej., requisitos de residencia de datos y múltiples nubes)
- Descubrimiento, categorización y almacenamiento en etapa intermedia de datos (administración de datos)

Google Cloud

Cuando diseña una arquitectura de procesamiento de datos, un Professional Data Engineer debe analizar los requisitos comerciales tanto actuales como futuros. La arquitectura diseñada debe ser altamente escalable ya que los datos aumentan a un ritmo exponencial. Muchas empresas usan un enfoque de múltiples nubes, por lo que un Professional Data Engineer debe poder diseñar una arquitectura de datos que sea altamente portátil y pueda trabajar sin problemas en distintos tipos de infraestructura.

La pregunta 7 puso a prueba tu conocimiento sobre cómo diseñar canalizaciones de datos para la portabilidad de los datos y aplicaciones. En la pregunta 8, se te pidió que explicaras cómo las herramientas de Google Cloud respaldan la categorización y el descubrimiento de datos.

1.3 | Análisis de la pregunta de diagnóstico 7



Estás usando Dataproc para procesar una gran cantidad de archivos CSV. La opción de almacenamiento que elijas debe ser flexible para adaptarse a muchos nodos trabajadores en varios clústeres. Estos nodos trabajadores leerán los datos y también los escribirán para el almacenamiento intermedio entre los trabajos de procesamiento.

- A. Cloud SQL
- B. Discos persistentes zonales
- C. SSD local
- D. Cloud Storage

¿Cuál es la opción de almacenamiento recomendada en Google Cloud?

Google Cloud

Comentarios:

- A. Incorrecto. Cloud SQL es adecuado para datos transaccionales, pero no es la opción recomendada para el procesamiento de datos de Dataproc.
- B. Incorrecto. Los discos persistentes zonales no son la opción recomendada para el almacenamiento de Dataproc.
- C. Incorrecto. Las SSD locales no son persistentes, por lo que no son una buena opción de almacenamiento cuando debes retener datos intermedios por un período más extenso que la vida del nodo trabajador.
- D. Correcto. Cloud Storage es la opción recomendada de almacenamiento centralizado para Dataproc. Ofrece muchos beneficios, como que cuenta con una alta disponibilidad de datos, no necesita administración de almacenamiento, ofrece un inicio rápido y provee Identity and Access Management (IAM) coherente.

Vínculos:

<https://cloud.google.com/blog/topics/developers-practitioners/dataproc-best-practices-guide>
<https://cloud.google.com/blog/products/storage-data-transfer/hdfs-vs-cloud-storage-pr-os-cons-and-migration-tips>

Más información:

Cursos:

Moderniza data lakes y almacenes de datos en Google Cloud

- Cómo crear un data lake

Procesamiento de datos sin servidores con Dataflow: Fundamentos

- Portabilidad de Beam

Resumen:


Cuando diseña canalizaciones de datos, un Professional Data Engineer (PDE) debería poder diseñar para la portabilidad de los datos y aplicaciones. Un aspecto de esto conlleva elegir una ubicación de almacenamiento apropiada para tus datos.

Cloud Storage es un sistema de archivos compatibles con Hadoop (HDFS) que admite trabajos de Hadoop y Spark con mínimos cambios. Está estrechamente integrado en Google Cloud y admite múltiples funciones, como Identity and Access Management (IAM), redundancia, alta disponibilidad y durabilidad, lo que hace que sea fácil trabajar con este producto de Google.

1.3 | Análisis de la pregunta de diagnóstico 8

Estás administrando los datos de Cymbal Retail, que incluyen varios equipos, como venta minorista, ventas, marketing y legal. Estos equipos consumen datos de varios productores, incluidos los sistemas de punto de venta, datos de la industria, pedidos y muchos más. Actualmente, los equipos que consumen datos tienen que pedirles constantemente a los equipos que los producen que verifiquen los datos más actualizados y aclaren otras cuestiones sobre estos, como la fuente y la propiedad. Este proceso no es confiable, requiere tiempo y, a menudo, conlleva reiteradas derivaciones. Debes implementar una solución centralizada que obtenga una vista unificada de los datos de la organización y mejore la capacidad de búsqueda.

¿Qué deberías hacer?

- 
- A. Implementar una malla de datos con Dataplex y pedirles a los productores que etiqueten los datos cuando se crean
 - B. Implementar un data lake con Cloud Storage y crear buckets para cada equipo, como el de venta minorista, ventas y marketing
 - C. Implementar un almacén de datos con BigQuery y crear conjuntos de datos para cada equipo, como el de venta minorista, ventas y marketing
 - D. Implementar paneles en Looker que ofrecen vistas de los datos que satisfacen los requisitos de cada uno de los equipos

Google Cloud

Comentarios:

- A. Correcto. Dataplex es una malla de datos que también incluye la capacidad de categorización de datos con Data Catalog. Los consumidores de datos pueden buscar y descubrir información fácilmente sin tener que esperar que los productores de datos respondan, lo que reduce los cuellos de botella en el análisis de datos.
- B. Incorrecto. Cloud Storage es una solución de almacén de objetos. Si bien podemos separar los datos en buckets, no incluye capacidades de etiquetado enriquecidas.
- C. Incorrecto. BigQuery puede separar los datos en conjuntos de datos, pero no es una solución centralizada de descubrimiento de datos que puede conservar diferentes tipos de datos.
- D. Incorrecto. Looker ofrece visualizaciones de datos basadas en los datos en sí. No incluye servicios inherentes de etiquetado de datos.

Vínculos:

<https://cloud.google.com/dataplex/docs/introduction>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Insignia de habilidad:

[Comienza a usar Dataplex](#)

Resumen:

A medida que aumentan los volúmenes de datos, se vuelve cada vez más difícil supervisarlos. Además, su linaje, controles de acceso, seguridad y otros metadatos pueden sobrecargar a los productores y consumidores de datos. Una malla de datos como Dataplex puede conservar metadatos en Data Catalog; algunos de los datos se pueden etiquetar automáticamente y otros se pueden etiquetar de forma manual, lo que ofrece información valiosa que hace que los datos se puedan consumir con facilidad en toda la organización.

1.3 | Diseño para la flexibilidad y la portabilidad

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- Portabilidad de Beam

Insignias de habilidad

[Comienza a usar Dataplex](#)

Documentación

[Prácticas recomendadas de Dataproc | Blog de Google Cloud](#)

[HDFS versus Cloud Storage: ventajas, desventajas y sugerencias para la migración | Blog de Google Cloud](#)

[Descripción general de Dataplex](#)

Analizaste algunas preguntas de diagnóstico que abordaron aspectos del diseño de tus sistemas de procesamiento de datos para la flexibilidad y la portabilidad. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/blog/topics/developers-practitioners/dataproc-best-practices-guide>

<https://cloud.google.com/blog/products/storage-data-transfer/hdfs-vs-cloud-storage-pros-cons-and-migration-tips>

<https://cloud.google.com/dataplex/docs/introduction>

1.4 | Diseño de migraciones de datos

Comprende las siguientes consideraciones:

- Análisis de las necesidades, los usuarios, los procesos y las tecnologías actuales de la parte interesada, y creación de un plan para llegar al estado deseado
- Planificación de la migración a Google Cloud (p. ej., Servicio de transferencia de datos de BigQuery, Database Migration Service, Transfer Appliance, redes de Google Cloud y Datastream)
- Diseño de la estrategia de validación de la migración
- Diseño de la arquitectura del proyecto, el conjunto de datos y las tablas para garantizar una administración de datos adecuada

Google Cloud

Un Professional Data Engineer debe prestar atención a varias consideraciones cuando migra datos desde centros de datos privados a Google Cloud. Deberías conocer las distintas herramientas disponibles para facilitar tu migración de datos a Google Cloud y poder elegir la herramienta más apropiada según el caso de uso. Una parte integral de la migración de datos incluye configurar estándares y políticas internos para recopilar, almacenar, procesar y eliminar los datos.

En la pregunta 9, se te pidió que describieras cómo diseñar proyectos de Google Cloud y el almacenamiento de datos para respaldar la administración de datos. En la pregunta 10, se evaluaron tus conocimientos sobre los recursos y las herramientas que te pueden ayudar a migrar datos a Google Cloud.

1.4 | Análisis de la pregunta de diagnóstico 9



Las leyes de la región en la que operas exigen que los archivos relacionados con todos los pedidos realizados cada día se almacenen de manera inmutable durante 365 días. La solución que recomiendas debe ser rentable.

¿Qué deberías hacer?

- A. Almacenar los datos en un bucket de Cloud Storage, habilitar el control de versiones de objetos y borrar las versiones de más de 365 días
- B. Almacenar los datos en un bucket de Cloud Storage y especificar un período de retención
- C. Almacenar los datos en un bucket de Cloud Storage y configurar una política de ciclo de vida para borrar el archivo después de 365 días
- D. Almacenar los datos en un bucket de Cloud Storage, habilitar el control de versiones de objetos y borrar las versiones de más de 365 días

Google Cloud

Comentarios:

A: Incorrecto. El control de versiones de objetos no impide que los archivos se modifiquen o borren.

B: Correcto. La retención de objetos es una opción integrada que te permite configurar cuánto tiempo se deberían conservar los archivos sin permitir que se realicen cambios.

C: Incorrecto. Esta opción automatiza la eliminación del archivo después de los 365 días, pero no restringe la posibilidad de borrarlo antes de ese plazo.

D: Incorrecto. El control de versiones de objetos no impide que los archivos se modifiquen o borren. Además, tener múltiples versiones de los objetos no es rentable.

Vínculos:

<https://cloud.google.com/storage/docs/bucket-lock>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake
- Cómo crear un almacén de datos

[Conceptos básicos de BigQuery para profesionales de Redshift](#)

- BigQuery y Google Cloud IAM

Resumen:

Las capacidades integradas de Cloud Storage para la administración del ciclo de vida se pueden configurar de manera sencilla y facilitan estas tareas importantes sin la necesidad de crear, operar o mantener soluciones personalizadas.

1.4 | Análisis de la pregunta de diagnóstico 10



Cymbal Retail está migrando sus centros de datos privados a Google Cloud. Durante muchos años, se acumularon cientos de terabytes de datos. Actualmente tienes una línea de 100 Mbps y debes transferir estos datos de manera confiable antes de comenzar las operaciones en Google Cloud en 45 días.

¿Qué deberías hacer?

- A. Almacenar los datos en un extremo HTTPS y configurar el Servicio de transferencia de almacenamiento para copiar los datos a Cloud Storage
- B. Subir los datos a Cloud Storage usando `gcloud storage`
- C. Comprimir y subir los datos a los buckets de Cloud Storage con la consola de Google Cloud
- D. Pedir un Transfer Appliance, exportar los datos y enviarlo a Google

Google Cloud

Comentarios:

- A: Incorrecto. El ancho de banda disponible no es suficiente para finalizar la transferencia de datos en el tiempo necesario.
- B: Incorrecto. `gcloud storage` es útil para unos pocos archivos de tamaño pequeño a mediano. En el caso de datos más grandes, se deberían considerar otras opciones de transferencia de datos.
- C: Incorrecto. Subir grandes cantidades de datos usando la consola de Google Cloud no es conveniente ni eficiente.
- D: Correcto. Si es necesario transferir grandes cantidades de datos en un mes, un Transfer Appliance es la opción adecuada.

Vínculos:

<https://cloud.google.com/architecture/migration-to-google-cloud-transferring-your-large-datasets#transfer-options>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Conceptos básicos de BigQuery para profesionales de Redshift](#)

- SQL en BigQuery

Resumen:

Para las transferencias de datos, debes considerar el ancho de banda de la red, la confiabilidad de la red y el plazo que debes cumplir. Cuando el ancho de banda disponible de la red es bajo, aumentará el tiempo de transferencia, lo cual puede que no sea viable para el negocio. En dichas circunstancias, resulta más conveniente transferir los datos a Google Cloud con un Transfer Appliance.

1.4 | Diseño de migraciones de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake
- Cómo crear un almacén de datos

[Conceptos básicos de BigQuery para profesionales de Redshift](#)

- BigQuery y Google Cloud IAM

Documentación

[Políticas de retención y bloqueos de estas políticas | Cloud Storage](#)

[Migración a Google Cloud: transfiere tus conjuntos de datos grandes](#)

Analizaste algunas preguntas de diagnóstico que abordaron distintos aspectos del diseño de migraciones de datos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/storage/docs/bucket-lock>

<https://cloud.google.com/architecture/migration-to-google-cloud-transferring-your-large-datasets#transfer-options>