





Cómo prepararte para convertirte en Professional Data Engineer

Módulo 2: Transferencia y procesamiento de datos

Te damos la bienvenida al Módulo 2: Transferencia y procesamiento de datos.

Revisión y plan de estudios




Google Cloud

Revisemos cómo usar estas preguntas de diagnóstico para identificar qué incluir en tu plan de estudios.

Recuerda que este curso no está diseñado para enseñarte todo lo que necesitas saber para el examen y que las preguntas de diagnóstico no incluyen todo lo que podría preguntarse en el examen. En su lugar, esta actividad se diseñó para ayudarte a comprender mejor el contenido de la sección y las diferentes habilidades que debes desarrollar en tu preparación para la certificación.

Tu plan de estudios:

Transferencia y procesamiento de datos



2.1

Planificación de las canalizaciones de datos

2.2

Creación de las canalizaciones

2.3

Implementación y puesta en funcionamiento de las canalizaciones

En la revisión, verás los objetivos de esta sección del examen y las preguntas que acabas de responder sobre cada uno de ellos. Presentaremos un objetivo, revisaremos brevemente las respuestas a las preguntas relacionadas y explicaremos dónde puedes encontrar más información en los recursos de aprendizaje o en la documentación de Google. A medida que revises el objetivo de cada sección, usa la página de tu cuaderno de ejercicios para marcar la documentación, los cursos y las insignias de habilidad en particular que quieras destacar en tu plan de estudios.

2.1 | Planificación de las canalizaciones de datos

Se incluyen las siguientes consideraciones:

- Definición de fuentes y receptores de datos
- Definición de la lógica de transformación de los datos
- Aspectos básicos de las redes
- Encriptación de los datos

Google Cloud

Una parte fundamental del rol que debe desempeñar un Professional Data Engineer es diseñar canalizaciones de datos, crearlas y realizar su mantenimiento. El primer paso para diseñar una canalización de datos es identificar dónde se originan los datos y dónde deberían residir finalmente. Un receptor de datos es, por lo general, un almacén de datos como BigQuery que permite el análisis posterior. Además, también necesitas tener en cuenta la seguridad de los datos cuando estos se transfieren de la fuente al receptor.

En la pregunta 1, se te pidió que encuentres las diferencias entre las opciones de fuentes de datos y selecciones la más adecuada para el caso de uso de una canalización de datos. En la pregunta 2 se te pidió que encuentres las diferencias entre las opciones de receptores de datos y selecciones la más adecuada para el caso de uso de una canalización de datos. En la pregunta 3, definiste la lógica de transformación adecuada para tus objetivos de canalizaciones de datos.

2.1 | Análisis de la pregunta de diagnóstico 1



Tu equipo de ingeniería de datos recibe datos en formato JSON de fuentes externas al final de cada día. Debes diseñar la canalización de datos.

¿Qué deberías hacer?

- A. Almacenar los datos en Cloud Storage y crear una canalización de extracción, transformación y carga (ETL)
- B. Configurar tu almacén de datos de BigQuery para que sea público y pedir a las fuentes externas que inserten los datos
- C. Crear una API pública para permitir que las aplicaciones externas agreguen datos a tu almacén
- D. Almacenar los datos en discos persistentes y crear una canalización de ETL

Google Cloud

Comentarios:

- A. Correcto. El enfoque recomendado para las canalizaciones de datos por lotes es almacenar los datos en Cloud Storage. Luego, debes crear una canalización de ETL (o ELT según el caso de uso) para transferir los datos a un almacén de datos.
- B. Incorrecto. No se recomienda configurar el almacén de datos como público. Es posible que los datos tampoco tengan las transformaciones que necesitas.
- C. Incorrecto. Es posible que los datos agregados por fuentes externas no tengan las transformaciones que necesitas.
- D. Incorrecto. No se recomienda almacenar los datos en discos persistentes para las canalizaciones de análisis de datos. Es preferible usar un almacenamiento centralizado y sin servidores, como Cloud Storage.

Vínculos:

<https://cloud.google.com/blog/topics/developers-practitioners/what-data-pipeline-architecture-should-i-use>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake
- Cómo crear un almacén de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones

- Fuentes y receptores

Insignias de habilidad:

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

Se recomienda usar Cloud Storage para el almacenamiento de las canalizaciones de datos que insertan datos por lotes, incluidos los casos en que los datos provienen de fuentes externas. Cloud Storage también sirve para crear copias de seguridad a largo plazo.

2.1 | Análisis de la pregunta de diagnóstico 2



La primera etapa de tu canalización de datos procesa decenas de terabytes de datos financieros y crea un conjunto de datos disperso de series temporales como un par clave-valor.

- A. Cloud Storage
- B. Cloud SQL
- C. AlloyDB
- D. Bigtable

¿Cuál de estas opciones es un receptor de datos adecuado para la primera etapa de la canalización?

Google Cloud

Comentarios:

- A. Incorrecto. Cloud Storage se usa para el almacenamiento de objetos y no es adecuado para una base de datos.
- B. Incorrecto. Cloud SQL admite bases de datos relacionales, las cuales no son tan convenientes como Bigtable para los datos dispersos de series temporales.
- C. Incorrecto. AlloyDB es una base de datos relacional, la cual no es tan adecuada como Bigtable para los datos dispersos de series temporales.
- D. Correcto. Bigtable es ideal para las aplicaciones que requieren capacidad de procesamiento alta y escalabilidad para datos de pares clave-valor, en los que el tamaño de cada valor no suele superar los 10 MB. Bigtable es la opción adecuada para las aplicaciones que trabajan con datos de series temporales, como las aplicaciones financieras.

Vínculos:

<https://cloud.google.com/bigtable/docs/overview>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos con Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de BigQuery y Bigtable con alta capacidad de procesamiento

Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones

- Fuentes y receptores

Insignias de habilidad:

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

Google Cloud es compatible con una gran variedad de bases de datos administradas. Al momento de elegir una opción para tus aplicaciones, debes identificar el tipo de datos que quieres almacenar, el tipo de uso que le darás (analítico o transaccional) y el escalamiento.

2.1 | Análisis de la pregunta de diagnóstico 3



Estás procesando grandes cantidades de datos de entrada en BigQuery. Necesitas combinar estos datos con una cantidad pequeña de datos que cambian con frecuencia y que están disponibles en Cloud SQL.

¿Qué deberías hacer?

- A. Copiar los datos de Cloud SQL a una tabla nueva de BigQuery cada una hora
- B. Copiar los datos de Cloud SQL y crear una tabla combinada y normalizada cada una hora
- C. Usar una consulta federada para obtener datos de Cloud SQL
- D. Crear una canalización de Dataflow para combinar los datos de BigQuery y Cloud SQL cuando los datos de Cloud SQL cambien

Google Cloud

Comentarios:

- A. Incorrecto. Dado que los datos cambian con frecuencia, importar la tabla una vez por hora podría producir resultados inexactos.
- B. Incorrecto. Dado que los datos cambian con frecuencia, importar la tabla una vez por hora podría producir resultados inexactos.
- C. Correcto. Dado que los datos cambian con frecuencia, puedes consultarlos in situ con las consultas federadas de BigQuery
- D. Incorrecto. Dado que los datos cambian con frecuencia, el procesamiento y los costos podrían ser excesivos.

Vínculos:

<https://cloud.google.com/bigquery/docs/cloud-sql-federated-queries>

<https://cloud.google.com/blog/products/data-analytics/exploring-new-features-in-bigquery-federated-queries>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Repaso de conceptos de Beam
- Esquemas

Resumen:

Algunos datos son estáticos, mientras que otros son dinámicos. Un Professional Data Engineer debe crear sistemas que integren los datos de diferentes fuentes y los transformen en función de las necesidades empresariales. Las consultas federadas permiten acceder a los datos de Cloud SQL directamente desde BigQuery. Esto es conveniente cuando los datos cambian con frecuencia.

2.1

Planificación de las canalizaciones de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Cómo crear un almacén de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de BigQuery y Bigtable con alta capacidad de procesamiento

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Repaso de conceptos de Beam
- Fuentes y receptores
- Esquemas

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[¿Qué arquitectura de canalización de datos debería usar? | Blog de Google Cloud](#)

[Descripción general de Bigtable](#)

[Consultas federadas de Cloud SQL | BigQuery](#)

[Explora nuevas funciones en las consultas federadas de BigQuery | Blog de Google Cloud](#)

Acabas de analizar varias preguntas de diagnóstico que abordaron distintos aspectos de la planificación de las canalizaciones de datos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/blog/topics/developers-practitioners/what-data-pipeline-architecture-should-i-use>

<https://cloud.google.com/bigtable/docs/overview>

<https://cloud.google.com/bigquery/docs/cloud-sql-federated-queries>

<https://cloud.google.com/blog/products/data-analytics/exploring-new-features-in-bigquery-federated-queries>

2.2 Creación de las canalizaciones

Se incluyen las siguientes consideraciones:

- Limpieza de datos
- Identificación de los servicios (p. ej., Dataflow, Apache Beam, Dataproc, Cloud Data Fusion, BigQuery, Pub/Sub, Apache Spark, el ecosistema de Hadoop y Apache Kafka)
- Transformaciones
 - Por lotes
 - Transmisión (p. ej., ventanas, datos tardíos)
 - Lenguaje
 - Transferencia de datos ad hoc (canalización automatizada o única)
- Importación y adquisición de datos
- Integración en fuentes de datos nuevas

Google Cloud

Como Professional Data Engineer, dedicarás una gran cantidad de tiempo a actividades de limpieza de datos. Si los datos entrantes están en su mayoría limpios, puedes usar herramientas como Dataprep para realizar el resto de la limpieza. Pero, la mayoría de las veces, los datos entrantes tendrán un formato sin procesar, por lo que deberás llevar a cabo un procesamiento de datos complejo para transformarlos a un formato adecuado. Como Professional Data Engineer, deberías estar familiarizado con las diversas herramientas, como Dataproc, Dataflow, Data Fusion y Dataprep, entre otras, y usar la herramienta adecuada para cada caso de uso. Deberás trabajar tanto con datos por lotes como con datos de transmisión en tiempo real. Las canalizaciones de datos de transmisión son significativamente más complejas que las canalizaciones por lotes, por lo que deberás estar al tanto de conceptos como el uso de ventanas, las entradas tardías y la evaluación temprana.

En la pregunta 4, se te pidió que encuentres las diferencias entre las opciones para el procesamiento de los datos. En la pregunta 5, se evaluaron tus conocimientos respecto de las opciones y consideraciones de los flujos de trabajo de datos por lotes y, en la pregunta 6, se te preguntó sobre las herramientas indicadas para los flujos de trabajo de datos por lotes de Google Cloud. En la pregunta 7, se evaluaron tus conocimientos sobre las opciones y consideraciones de los flujos de trabajo de datos de transmisión y, en la pregunta 8, se te preguntó sobre las herramientas indicadas para los flujos de trabajo de datos de transmisión de Google Cloud.

2.2 | Análisis de la pregunta de diagnóstico 4



Tu empresa cuenta con muchos analistas de datos, pero tiene un equipo de ingeniería de datos limitado. Debes elegir una herramienta con la que los analistas puedan crear canalizaciones de datos ellos mismos desde una interfaz gráfica de usuario.

- A. Dataflow
- B. Cloud Data Fusion
- C. Dataproc
- D. Cloud Composer

¿Cuál de estos productos es la opción más adecuada?

Google Cloud

Comentarios:

- A. Incorrecto. Para usar Dataflow, se necesitan conocimientos de programación.
- B. Correcto. La IU web de Cloud Data Fusion te permite crear soluciones de integración de datos escalables para limpiar, preparar, combinar, transferir y transformar datos, sin tener que administrar la infraestructura.
- C. Incorrecto. Para usar Dataproc, se necesitan bastantes conocimientos técnicos.
- D. Incorrecto. Con Cloud Composer, necesitas crear una canalización con código.

Vínculos:

<https://cloud.google.com/data-fusion/docs/concepts/overview>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes
- Ejecuta Spark en Dataproc
- Procesamiento de datos sin servidores con Dataflow
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

Resumen:

Google Cloud ofrece diversas herramientas para crear canalizaciones de datos. Identifica el caso de uso para la canalización de datos y selecciona la herramienta

adecuada. Por ejemplo, para usar Dataflow y Cloud Composer, se precisan conocimientos de programación. Otras herramientas, como Dataprep y Cloud Fusion, requieren menos conocimientos técnicos. Las herramientas de procesamiento de datos de Google Cloud a menudo también cuentan con equivalentes de código abierto. Si los trabajos de procesamiento de datos se están migrando a Google Cloud, elige la solución administrada que corresponda.

2.2 | Análisis de la pregunta de diagnóstico 5



Administras una canalización de datos por lotes de PySpark con Dataproc. Quieres adoptar un enfoque práctico para la ejecución de la carga de trabajo, pero no quieres aprovisionar ni administrar tus propios clústeres.

¿Qué deberías hacer?

- A. Configurar el trabajo para ejecutarlo en Dataproc Serverless
- B. Configurar el trabajo para ejecutarlo con VMs Spot
- C. Volver a escribir el trabajo en Spark SQL
- D. Volver a escribir el trabajo en Dataflow con SQL

Google Cloud

Comentarios:

- A. Correcto. Dataproc Serverless aprovisionará los recursos automáticamente para ejecutar tu trabajo de Dataproc.
- B. Incorrecto. Configurar VMs Spot es una estrategia de reducción de costos, pero no de reducción de esfuerzos.
- C. Incorrecto. Ejecutar un trabajo de Spark SQL no resuelve automáticamente la administración de los clústeres.
- D. Incorrecto. Volver a escribir los trabajos en Dataflow requiere más esfuerzo.

Vínculos:

<https://cloud.google.com/dataproc-serverless/docs/overview>

Más información:

Cursos:

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- Separación de procesamiento y almacenamiento con Dataflow

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Rendimiento

Resumen:

Cuando te desempeñes como Professional Data Engineer, querrás reducir el tiempo dedicado a tareas repetitivas. El aprovisionamiento y la administración de los recursos para los trabajos de datos por lotes de larga duración es una de estas

tareas. Los trabajos por lotes pueden ejecutarse durante horas o incluso días, por lo que no querrás supervisar manualmente la capacidad. Google Cloud ofrece diversas opciones sin servidores, incluso para algunas cargas de trabajo de Dataproc. Su uso puede reducir el esfuerzo destinado a la administración de los clústeres.

2.2 | Análisis de la pregunta de diagnóstico 6



Necesitas ejecutar trabajos por lotes, lo que puede demorar muchos días en finalizar. No quieres administrar el aprovisionamiento de la infraestructura.

- A. Usar Cloud Scheduler para ejecutar los trabajos
- B. Usar Workflows para ejecutar los trabajos
- C. Ejecutar los trabajos en Batch
- D. Usar Cloud Run para ejecutar los trabajos

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Cloud Scheduler te permite programar un evento en el futuro, pero no asigna recursos automáticamente.
- B. Incorrecto. Workflows es la opción recomendada cuando quieres conectar una serie de tareas breves.
- C. Correcto. Batch es un servicio completamente administrado que programa, pone en cola y ejecuta las cargas de trabajo de procesamiento por lotes en Google Cloud. Se aprovisionan y administran los recursos y la capacidad según tus requisitos.
- D. Incorrecto. Cloud Run tiene límites respecto del tiempo máximo de un proceso en ejecución y no es una opción viable para los trabajos de procesamiento de datos de larga duración.

Vínculos:

<https://www.youtube.com/watch?v=RS7UJhD4R48>

<https://cloud.google.com/batch/docs/get-started>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- Separación de procesamiento y almacenamiento con Dataflow

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores

Insignia de habilidad:

[Prepara datos para las APIs de AA en Google Cloud](#)

Resumen:

Batch está diseñado para ejecutar trabajos por lotes de larga duración. Es un servicio administrado que aprovisiona recursos automáticamente para ejecutar el procesamiento por lotes que configures.

2.2 | Análisis de la pregunta de diagnóstico 7



Estás creando una canalización de datos de transmisión en Dataflow para los datos de los puntos de venta de Cymbal Retail. Quieres calcular la cantidad total de ventas por hora de forma continua.

- A. Ventanas de salto (llamadas ventanas deslizantes en Apache Beam)
- B. Ventanas de sesión
- C. Ventana global
- D. Ventanas de saltos de tamaño constante (llamadas ventanas fijas en Apache Beam)

¿Cuál de estas opciones de ventanas deberías usar?

Google Cloud

Comentarios:

- A. Incorrecto. Las ventanas de salto (llamadas ventanas deslizantes en Apache Beam) pueden superponerse y no son la opción adecuada para esta necesidad.
- B. Incorrecto. Las ventanas de sesión son adecuadas para los casos de uso con brechas en la actividad, lo que no se aplica en este caso.
- C. Incorrecto. Una ventana global se aplica a todo el conjunto de datos y no es la opción adecuada para obtener resultados intermedios.
- D. Correcto. Las ventanas de saltos de tamaño constante (llamadas ventanas fijas en Apache Beam) tienen una duración fija y no se superponen, por lo que son la opción ideal para este caso.

Vínculos:

<https://cloud.google.com/dataflow/docs/concepts/streaming-pipelines>
<https://beam.apache.org/documentation/basics/#window>

Más información:

Cursos:

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores
- Estado y temporizadores
- Dataflow SQL y DataFrames

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Rendimiento
- Pruebas y CI/CD
- Plantillas de Flex

Resumen:

Cuando los datos no son finitos, pero necesitas ver resultados intermedios, las ventanas te permiten separar todo el período en intervalos intermedios de procesamiento. Cuando se combina con las marcas de agua y los activadores, el uso de ventanas permite que los desarrolladores tengan la flexibilidad de controlar el momento en que se realiza el procesamiento de los datos.

2.2 | Análisis de la pregunta de diagnóstico 8



Quieres crear una canalización de análisis de datos de transmisión en Google Cloud. Debes elegir los productos adecuados para trabajar con datos de transmisión.

- A. Pub/Sub, Dataflow, BigQuery
- B. Pub/Sub, Dataprep y BigQuery
- C. Cloud Storage, Dataflow y Cloud SQL
- D. Cloud Storage, Dataprep y AlloyDB

¿Cuál de estas opciones elegirías?

Google Cloud

Comentarios:

- A. Correcto. Pub/Sub, Dataflow y BigQuery admiten datos de transmisión y forman la canalización recomendada para el procesamiento continuo de datos.
- B. Incorrecto. Dataprep no admite el procesamiento de datos de transmisión.
- C. Incorrecto. Cloud Storage es adecuado para trabajar con data lakes, pero no para datos de transmisión. Cloud SQL es una solución de almacenamiento transaccional que no tiene funcionalidades de transmisión.
- D. Incorrecto. Cloud Storage es adecuado para trabajar con data lakes, pero no para datos de transmisión. AlloyDB es una base de datos transaccional.

Vínculos:

<https://cloud.google.com/solutions/stream-analytics>

Más información:

Cursos:

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub
- Funciones de transmisión de Dataflow

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- Separación de procesamiento y almacenamiento con Dataflow

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores
- Estado y temporizadores
- Dataflow SQL y DataFrames

Resumen:

Para el análisis de transmisiones, se requieren herramientas que se ajusten al procesamiento continuo. En Google Cloud, Pub/Sub, BigQuery, Dataflow y Datastream son algunas de las herramientas que se recomiendan para el análisis de transmisiones.

2.2 Creación de las canalizaciones

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes
- Ejecuta Spark en Dataproc
- Procesamiento de datos sin servidores con Dataflow
- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub
- Funciones de transmisión de Dataflow

[Procesamiento de datos sin servidores con Dataflow: fundamentos](#)

- Separación de procesamiento y almacenamiento con Dataflow

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores
- Estados y temporizadores
- Dataflow SQL y DataFrames

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Rendimiento
- Pruebas y CI/CD
- Plantillas de Flex

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

Documentación

[Descripción general de Cloud Data Fusion](#)

[¿Qué es Dataproc Serverless?](#)

[Introducción a Google Batch](#)

[Comienza a usar Batch | Google Cloud](#)

[Canalizaciones de transmisión | Cloud Dataflow](#)

[Conceptos básicos del modelo de Beam](#)

[Soluciones de análisis de transmisiones | Google Cloud](#)

Las preguntas de diagnóstico que acabamos de revisar analizan algunos de los aspectos relacionados con la creación de canalizaciones de datos. Estos son algunos cursos y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/data-fusion/docs/concepts/overview>

<https://cloud.google.com/dataproc-serverless/docs/overview>

<https://www.youtube.com/watch?v=RS7UJhD4R48>

<https://cloud.google.com/batch/docs/get-started>

<https://cloud.google.com/dataflow/docs/concepts/streaming-pipelines>

<https://beam.apache.org/documentation/basics/#window>

<https://cloud.google.com/solutions/stream-analytics>

2.3 | Implementación y puesta en funcionamiento de las canalizaciones

Comprende las siguientes consideraciones:

- Automatización y organización de trabajos (p. ej., Cloud Composer y Workflows)
- CI/CD (integración continua e implementación continua)

Google Cloud

Un Professional Data Engineer necesita crear, programar y supervisar flujos de trabajo de forma programática. Cloud Composer está integrado en el proyecto Apache Airflow y ofrece una herramienta única de organización de canalizaciones tanto locales como en múltiples nubes o completamente en Google Cloud. Como Professional Data Engineer, deberás diseñar y, también, implementar canalizaciones de integración continua y entrega continua de extremo a extremo.

En la pregunta 9, se te preguntó sobre las herramientas para la organización de los trabajos y los flujos de trabajo en Google Cloud. En la pregunta 10, se evaluaron tus conocimientos sobre cómo la CI/CD te ayuda a implementar y poner en funcionamiento las canalizaciones de datos.

2.3 | Análisis de la pregunta de diagnóstico 9



Tienes una canalización de datos que requiere que supervises un bucket de Cloud Storage en busca de un archivo, inicies un trabajo de Dataflow para procesar los datos de ese archivo, ejecutes una secuencia de comandos de shell para validar los datos procesados en BigQuery y, luego, borres el archivo original. Necesitas organizar esta canalización con las herramientas recomendadas.

- A. Cloud Tasks
- B. Cloud Composer
- C. Cloud Scheduler
- D. Cloud Run

¿Qué producto deberías elegir?

Google Cloud

Comentarios:

- A. Incorrecto. Cloud Tasks se usa para la ejecución de tareas asíncronas y no es la herramienta recomendada para la organización de canalizaciones de datos.
- B. Correcto. Cloud Composer, una versión administrada de Apache Airflow, puede organizar una serie de tareas de canalizaciones de datos.
- C. Incorrecto. Cloud Scheduler es un servicio de trabajos cron que puede ejecutar aplicaciones a la hora programada.
- D. Incorrecto. Cloud Run ejecuta aplicaciones de contenedores sin servidores. No es la herramienta adecuada para la organización de canalizaciones de datos.

Vínculos:

<https://youtu.be/3UfYwR3Uwqw?t=169>

<https://cloud.google.com/composer/docs/concepts/overview>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Pruebas y CI/CD

Insignia de habilidad:

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

Google Cloud ofrece diversas herramientas, como Dataproc, Dataflow, Data Fusion y Dataprep. Como Professional Data Engineer, debes conocer las funcionalidades de cada producto y elegir las opciones correctas. Cloud Composer se basa en Apache Airflow. Incluso, puedes crear tus canalizaciones con el proyecto de Apache Airflow de código abierto y ejecutarlas en Google Cloud con Cloud Composer.

2.3 | Análisis de la pregunta de diagnóstico 10



Estás ejecutando trabajos de Dataflow para el procesamiento de datos. Cuando los desarrolladores actualizan el código en Cloud Source Repositories, necesitas probar y, luego, implementar el código actualizado con poco esfuerzo.

- A. Terraform
- B. Compute Engine
- C. Cloud Code
- D. Cloud Build

¿Cuál de las siguientes opciones deberías usar para crear tu canalización de integración continua y entrega continua (CI/CD) con el objetivo de procesar los datos?

Google Cloud

Comentarios:

- A. Incorrecto. Terraform es una opción adecuada para la administración automática de la infraestructura, pero no es una solución de CI/CD.
- B. Incorrecto. Compute Engine requerirá mucho más esfuerzo, ya que hay que instalar el software necesario y aprovisionar los recursos de compilación.
- C. Incorrecto. Cloud Code se integra en los entornos de desarrollo integrados (IDE) más populares para que trabajar con Google Cloud sea más fácil. No es una solución de CI/CD ni un sistema de compilación en sí mismo.
- D. Correcto. Cloud Build se puede configurar para buscar actualizaciones en el repositorio de código fuente y activar una serie de pasos, si es necesario, para implementar una canalización de CI/CD.

Vínculos:

<https://cloud.google.com/architecture/cicd-pipeline-for-data-processing>

Más información:

Cursos:

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Pruebas y CI/CD

Resumen:

Un Professional Data Engineer debe encontrar formas de automatizar los sistemas y lograr que sean confiables. Un proceso manual en el que los usuarios deben buscar los cambios y, luego, tomar medidas no es escalable. Cloud Build está integrado en

los repositorios de código y asigna los recursos necesarios automáticamente para ejecutar los pasos de la canalización de CI/CD.

2.3 Implementación y puesta en funcionamiento de las canalizaciones

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Pruebas y CI/CD

Insignias de habilidad

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Cómo usar Cloud Composer para organizar datos](#)

[Descripción general de Cloud Composer](#)

[Usa una canalización de CI/CD para tu flujo de trabajo de procesamiento de datos | Google Cloud](#)

Acabas de revisar las preguntas de diagnóstico relacionadas con la implementación y la puesta en funcionamiento de tus canalizaciones de datos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://youtu.be/3UfYwR3Uwqw?t=169>

<https://cloud.google.com/composer/docs/concepts/overview>

<https://cloud.google.com/architecture/cicd-pipeline-for-data-processing>