





Cómo prepararte para convertirte en Professional Data Engineer

Módulo 3: Almacenamiento de datos

Te damos la bienvenida al Módulo 3: Almacenamiento de datos.

Revisión y plan de estudios




Google Cloud

Revisemos cómo usar estas preguntas de diagnóstico para identificar qué incluir en tu plan de estudios.

Recuerda que este curso no está diseñado para enseñarte todo lo que necesitas saber para el examen y las preguntas de diagnóstico no incluyen todo lo que podría preguntarse en el examen. En su lugar, esta actividad se diseñó para ayudarte a comprender mejor el contenido de la sección y las diferentes habilidades que debes desarrollar en tu preparación para la certificación.

Tu plan de estudios:

Almacenamiento de los datos



3.1

Selección de sistemas de almacenamiento

3.2

Planificación del uso de un almacén de datos

3.3

Uso de un data lake

3.4

Diseño de una malla de datos

Google Cloud

En la revisión, verás los objetivos de esta sección del examen y las preguntas que acabas de responder sobre cada uno de ellos. Presentaremos un objetivo, revisaremos brevemente las respuestas a las preguntas relacionadas y explicaremos dónde puedes encontrar más información en los recursos de aprendizaje o en la documentación de Google. A medida que revises el objetivo de cada sección, usa la página de tu cuaderno de ejercicios para marcar la documentación, los cursos y las insignias de habilidad en particular que quieras destacar en tu plan de estudios.

3.1 Selección de sistemas de almacenamiento

Comprende las siguientes consideraciones:

- Análisis de patrones de acceso a datos
- Elección de servicios administrados (p. ej., Bigtable, Spanner, Cloud SQL, Cloud Storage, Firestore, Memorystore)
- Planificación de los costos y el rendimiento del almacenamiento
- Administración del ciclo de vida de los datos

Google Cloud

Google Cloud ofrece varios servicios para almacenar datos. Como Professional Data Engineer, debes conocer todas las ofertas y elegir un servicio adecuado según tu caso de uso. Por ejemplo, ¿necesitas una base de datos relacionales de SQL para almacenar datos transaccionales? O ¿necesitas un repositorio centralizado para almacenar tus datos no estructurados? Junto con el tipo de datos, también debes considerar los costos de almacenamiento y las implicaciones de rendimiento de cada servicio de almacenamiento.

En la pregunta 1, se te solicitó diferenciar entre servicios administrados para el almacenamiento de datos con el objetivo de seleccionar la opción más adecuada para un caso de uso determinado. En la pregunta 2, se evaluó tu habilidad para determinar cómo planificar los costos de mantenimiento y el rendimiento.

3.1 | Análisis de la pregunta de diagnóstico 1



Debes elegir una solución de almacenamiento de datos para admitir un sistema transaccional. Tus clientes se encuentran principalmente en una región. Quieres reducir las tareas administrativas y concentrar los esfuerzos de ingeniería en la creación de una aplicación empresarial.

- A. Usar Spanner
- B. Usar Cloud SQL
- C. Instalar una base de datos que desees en una VM de Compute Engine
- D. Crear un bucket de Cloud Storage con un bucket regional

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Spanner es más adecuado para un requisito de base de datos transaccional y global.
- B. Correcto. Cloud SQL es un servicio administrado que admite las populares bases de datos transaccionales MySQL, PostgreSQL y SQL Server.
- C. Incorrecto. Instalar y mantener tu propia instancia de base de datos supone un mayor esfuerzo para el equipo de ingeniería.
- D. Incorrecto. Un bucket de Cloud Storage no es una base de datos transaccional.

Vínculos:

<https://cloud.google.com/sql>

<https://cloud.google.com/sql/docs/introduction>

Más información:

Cursos:

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Macrodatos y aprendizaje automático en Google Cloud

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Cómo crear un almacén de datos

Crea sistemas resilientes de análisis de transmisiones en Google Cloud

- Funciones de transmisión de BigQuery y Bigtable con alta capacidad de procesamiento

Resumen:

Se requiere un Professional Data Engineer que comprenda tanto los requisitos técnicos como los comerciales. A veces, los esfuerzos y gastos vinculados a la administración de bases de datos no son adecuados para el negocio. Puedes optar entre varios servicios administrados en Google Cloud.

3.1 | Análisis de la pregunta de diagnóstico 2



Debes almacenar datos por un tiempo prolongado y usarlos para crear informes trimestrales.

- A. Standard
- B. Nearline
- C. Coldline
- D. Archive

¿Qué clase de almacenamiento deberías elegir?

Google Cloud

Comentarios:

- A. Incorrecto. La clase de almacenamiento Standard Storage es la opción recomendada cuando es necesario acceder a los datos frecuentemente; por ejemplo, una vez por día o por semana.
- B. Incorrecto. La clase de almacenamiento Nearline Storage es la opción recomendada cuando es necesario acceder a los datos con menor frecuencia; por ejemplo, una vez por mes.
- C. Correcto. La clase de almacenamiento Coldline Storage es la opción recomendada cuando es necesario acceder a los datos con muy poca frecuencia; por ejemplo, una vez por trimestre.
- D. Incorrecto. La clase de almacenamiento Archive Storage es la opción recomendada cuando se accede a los datos muy rara vez; por ejemplo, una vez por año o menos.

Vínculos:

<https://cloud.google.com/storage/docs/storage-classes>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Resumen:

Google Cloud tiene diferentes clases de almacenamiento cuyos precios dependen de

la cantidad de datos almacenados y la frecuencia con la que se accede a estos. Un Professional Data Engineer debe comprender la frecuencia esperada de acceso a los datos y planificar una clase de almacenamiento adecuada.

3.1 Selección de sistemas de almacenamiento

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Macrodatos y aprendizaje automático en Google Cloud

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un data lake
- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de BigQuery y Bigtable con alta capacidad de procesamiento

Documentación

[Cloud SQL para MySQL, PostgreSQL y SQL Server](#)

[¿Qué es Cloud SQL?](#)

[Clases de almacenamiento | Google Cloud](#)

Analizaste algunas preguntas de diagnóstico en las que se abordaban distintos aspectos de la selección de sistemas de almacenamiento para tus datos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/sql>

<https://cloud.google.com/sql/docs/introduction>

<https://cloud.google.com/storage/docs/storage-classes>

3.2 | Planificación del uso de un almacén de datos

Comprende las siguientes consideraciones:

- Diseño del modelo de datos
- Decisión del grado de normalización de datos
- Asignación de requisitos comerciales
- Definición de la arquitectura para respaldar los patrones de acceso a los datos

Google Cloud

Como Professional Data Engineer, implementarás un almacén de datos para almacenar y analizar tus datos. Google Cloud ofrece BigQuery, un almacén de datos empresarial sin servidores y rentable que funciona en varias nubes y escala con tus datos. Como Professional Data Engineer, crearás modelos de datos, decidirás el grado de normalización de datos y finalizarás el esquema. Una habilidad clave es entender los requisitos del negocio, asignarlos a los patrones de acceso a los datos más utilizados y optimizar la arquitectura de acuerdo con la manera en la que usas los datos.

En la pregunta 3, se evaluaron tus conocimientos sobre cómo diseñar el modelo de datos y los esquemas de tablas para un almacén de datos. En la pregunta 4, se te pidió describir cómo asignar requisitos del negocio al diseño y a la implementación de un almacén de datos. En la pregunta 5, se evaluó tu habilidad para definir la arquitectura de un almacén de datos que admita el acceso a los datos.

3.2 | Análisis de la pregunta de diagnóstico 3



Tienes varias tablas grandes en tus bases de datos transaccionales. Debes transferir todos los datos a BigQuery para que los analistas de negocios los exploren y analicen.

- A. Conservar los datos en BigQuery con el mismo esquema que la fuente
- B. Combinar todas las tablas de bases de datos transaccionales en una sola tabla con uniones externas
- C. Rediseñar el esquema para normalizar los datos a través de la eliminación de todas las redundancias
- D. Rediseñar el esquema para desnormalizar los datos con datos anidados y repetidos

¿Cómo deberías diseñar el esquema en BigQuery?

Google Cloud

Comentarios:

- A. Incorrecto. La forma normalizada en las bases de datos transaccionales es eficiente para las operaciones de escritura, pero no es eficiente para la ejecución de consultas.
- B. Incorrecto. La combinación de varias tablas en una sola tabla únicamente con uniones externas podría incluir mucha más redundancia de la necesaria. En BigQuery, es mejor que haya menos tablas, pero hay que analizar cómo diseñar el esquema.
- C. Incorrecto. La normalización de los datos no es el enfoque recomendado para BigQuery.
- D. Correcto. La desnormalización de los datos es el enfoque recomendado. Unir grandes cantidades de datos de forma reiterada durante el análisis de datos aumenta los costos.

Vínculos:

<https://cloud.google.com/bigquery/docs/best-practices-performance-overview>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

Insignia de habilidad:

[Crea un almacén de datos con BigQuery](#)

Resumen:

Las bases de datos orientadas a estadísticas, como BigQuery, tienen significativamente más solicitudes de lectura que solicitudes de escritura. En esta situación, el motor de análisis se optimiza para el rendimiento de las consultas a costa de la redundancia de datos. BigQuery también puede usar otras optimizaciones como la partición y el agrupamiento en clústeres para mejorar aún más el rendimiento de las consultas.

3.2 | Análisis de la pregunta de diagnóstico 4



Estás transfiriendo rápidamente datos que se distribuyen en un amplio rango de fechas en BigQuery. Debes particionar la tabla para mejorar el rendimiento de las consultas.

¿Qué deberías hacer?

- A. Crear una tabla particionada por tiempo de transferencia con tipo de partición por día
- B. Crear una tabla particionada por tiempo de transferencia con tipo de partición por año
- C. Crear una tabla particionada de rango de número entero
- D. Crear una tabla particionada por columnas de unidad de tiempo con tipo de participación por año

Google Cloud

Comentarios:

- A. Correcto. Un tipo de partición diaria es el más adecuado dado el volumen de los datos y el rango de fechas.
- B. Incorrecto. Con un tipo de partición anual, tienes demasiados datos por partición, lo que hace que las consultas sean ineficientes.
- C. Incorrecto. Un tipo de partición de rango de números enteros no es adecuado dado que las fechas definen los datos.
- D. Incorrecto. Un tipo de partición por año tiene demasiados datos por partición, lo que hace que las consultas sean ineficientes.

Vínculos:

https://cloud.google.com/bigquery/docs/partitioned-tables#date_timestamp_partitioned_tables

https://cloud.google.com/bigquery/docs/creating-partitioned-tables#create_a_time-unit_column-partitioned_table

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Insignia de habilidad:

[Crea un almacén de datos con BigQuery](#)

Resumen:

Cuando es necesario tener rendimiento y rentabilidad en BigQuery, el ingeniero de datos puede reducir la cantidad de datos consultada particionando la tabla. Según el tipo y el volumen de los datos, puedes elegir entre muchos tipos de particiones.

3.2 | Análisis de la pregunta de diagnóstico 5



Los analistas ejecutan de forma reiterada las mismas consultas complejas que combinan y filtran una gran cantidad de datos en BigQuery. Los datos cambian con frecuencia. Necesitas reducir el esfuerzo de los analistas.

- A. Crear un conjunto de datos con los datos que se consultan con frecuencia
- B. Crear una vista de los datos consultados con frecuencia
- C. Exportar los datos consultados con frecuencia a una tabla nueva
- D. Exportar los datos consultados con frecuencia a Cloud SQL

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Este no es un enfoque recomendado, ya que habrá datos redundantes.
- B. Correcto. La creación de una vista volverá a ejecutar la consulta compleja automáticamente. Mientras tanto, los analistas solo deben hacer referencia al nombre de la vista, lo que resulta más sencillo para ellos.
- C. Incorrecto. Este no es un enfoque recomendado, ya que habrá datos redundantes.
- D. Incorrecto. Duplicar los datos en otra base de datos requiere más esfuerzo y es más costoso.

Vínculos:

<https://cloud.google.com/bigquery/docs/views-intro>

Resumen:

Un Professional Data Engineer debe atender a los clientes internos y facilitar el proceso para que puedan trabajar con los datos. BigQuery admite una variedad de definiciones de datos, lo que incluye conjuntos de datos, tablas, vistas y vistas materializadas. Definir una vista con una consulta facilitará que otras personas reutilicen la misma consulta sin tener que conocer los detalles complejos.

3.2 | Planificación del uso de un almacén de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Insignias de habilidad

[Crea un almacén de datos con BigQuery](#)

Documentación

[Introducción a la optimización del rendimiento de consultas | BigQuery | Google Cloud](#)

[Introducción a las tablas particionadas | BigQuery | Google Cloud](#)

[Crea tablas particionadas | BigQuery | Google Cloud](#)

[Introducción a las vistas | BigQuery | Google Cloud](#)

En las preguntas de diagnóstico que acabas de revisar, se abordaron algunos aspectos de la planificación para usar un almacén de datos. Estos son algunos cursos y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/bigquery/docs/best-practices-performance-overview>

https://cloud.google.com/bigquery/docs/partitioned-tables#date_timestamp_partitioned_tables

https://cloud.google.com/bigquery/docs/creating-partitioned-tables#create_a_time-unit_column-partitioned_table

<https://cloud.google.com/bigquery/docs/views-intro>

3.3 | Uso de un data lake

Comprende las siguientes consideraciones:

- Administración del lake (configuración de descubrimiento de datos, acceso y controles de costos)
- Procesamiento de datos
- Supervisión del data lake

Google Cloud

Como Professional Data Engineer, implementarás un data lake para tu organización. Serás responsable de garantizar el rendimiento del acceso, reducir los costos de almacenamiento, asegurar la disponibilidad de los datos y proteger los datos.

En la pregunta 6, se te pidió que describieras cómo diseñar y administrar un data lake para controlar los costos. En la pregunta 7, se puso a prueba tu conocimiento sobre cómo administrar un data lake para el descubrimiento de datos y su seguridad. En la pregunta 8, se evaluó tu conocimiento de las opciones para supervisar un data lake.

3.3 | Análisis de la pregunta de diagnóstico 6



Tienes datos que se transfieren a diario y se analizan con frecuencia en el primer mes. Luego, los datos se conservan únicamente para las auditorías, que se realizan de manera ocasional cada cierta cantidad de años. Debes configurar un almacenamiento rentable.

- A. Crear un bucket en Cloud Storage con el control de versiones de objetos configurado
- B. Crear un bucket en Cloud Storage con la función Autoclass configurada
- C. Configurar una política de retención de datos en Cloud Storage
- D. Configurar una política de ciclo de vida en Cloud Storage

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. El control de versiones de objetos conserva las versiones de los objetos, pero aumenta los costos.
- B. Incorrecto. Una configuración Autoclass transferirá los datos automáticamente a diferentes clases, pero no tendrás un control detallado sobre el momento en el que sucederá ni a qué clase.
- C. Incorrecto. Las políticas de retención restringen la modificación del objeto, pero no reducen el costo.
- D. Correcto. Una política de ciclo de vida puede configurarse para transferir automáticamente los objetos entre diferentes clases de almacenamiento según los programas que determines.

Vínculos:

<https://cloud.google.com/storage>

<https://cloud.google.com/storage/docs/lifecycle>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Resumen:

Las organizaciones transfieren grandes cantidades de datos. El almacenamiento genera costos y, sin embargo, es necesario para cumplir con varios requisitos, como

auditorías y normativas. Un Professional Data Engineer debe buscar maneras rentables de almacenar datos según la frecuencia de uso prevista.

3.3 | Análisis de la pregunta de diagnóstico 7



Tienes datos almacenados en un bucket de Cloud Storage. Estás usando tanto Identity and Access Management (IAM) como Listas de control de acceso (ACL) para configurar el control de acceso.

¿Qué afirmación describe el acceso de un usuario a los objetos en el bucket?

- A. El usuario no tiene acceso si IAM rechaza el permiso.
- B. El usuario solo tiene acceso si tanto IAM como las ACL otorgan un permiso.
- C. El usuario tiene acceso si IAM o las ACL otorgan un permiso.
- D. El usuario no tiene acceso si IAM o las ACL deniegan un permiso.

Google Cloud

Comentarios:

- A. Incorrecto. Las ACL pueden anular los permisos de IAM.
- B. Incorrecto. No es necesario que los permisos estén definidos de manera congruente en ambos porque cualquiera de ellos puede otorgar acceso.
- C. Correcto. IAM y las ACL trabajan en paralelo. Si cualquiera de los dos sistemas otorga permiso de acceso al usuario, el usuario tendrá acceso.
- D. Incorrecto. Cualquiera de los sistemas puede anular el permiso que estableció el otro.

Vínculos:

<https://cloud.google.com/storage/docs/access-control>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Resumen:

Como Professional Data Engineer responsable de los datos y su seguridad, Google Cloud te permite configurar un control detallado sobre los permisos de acceso. Tienes opciones como IAM, ACL, URLs firmadas y documentos de políticas firmados. IAM te otorga control a nivel de bucket, y las ACL te proporcionan control a nivel de objeto. Puedes usar cualquiera para configurar el acceso.

3.3 | Análisis de la pregunta de diagnóstico 8



Un gerente de Cymbal Retail expresa su preocupación por el acceso no autorizado a los objetos en el bucket de Cloud Storage. Debes evaluar todos los accesos a todos los objetos en el bucket.

¿Qué deberías hacer?

- A. Revisar los registros de auditoría de actividad del administrador
- B. Habilitar y, luego, revisar los registros de auditoría de acceso a los datos
- C. Enrutar los registros de actividad del administrador a un receptor de BigQuery y analizar los registros con consultas en SQL
- D. Cambiar los permisos en el bucket a solo los empleados de confianza

Google Cloud

Comentarios:

- A. Incorrecto. Los registros de auditoría de actividad del administrador no muestran quién lee y escribe los objetos.
- B. Correcto. Los registros de auditoría de acceso a los datos primero tienen que habilitarse específicamente porque podrían generar una gran cantidad de registros para todas las operaciones de lectura y escritura.
- C. Incorrecto. Enrutar los registros de auditoría de actividad del administrador hacia BigQuery para su análisis no ayudará porque no mostrarán quién lee y escribe los objetos.
- D. Incorrecto. Cambiar los permisos limitará el uso. Sin embargo, no podrás descubrir quién accede actualmente a los objetos.

Vínculos:

<https://cloud.google.com/storage/docs/audit-logging>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Resumen:

Los registros ayudan a un Professional Data Engineer a analizar lo sucedido: quién accedió a qué documentos y cuándo. Los registros de auditoría de actividad del administrador siempre están activados, mientras que los registros de auditoría de

acceso a los datos deben habilitarse.

3.3 | Uso de un data lake

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Documentación

[Cloud Storage](#)

[Administración del ciclo de vida de los objetos | Cloud Storage](#)

[Descripción general del control de acceso | Cloud Storage](#)

[Registros de auditoría de Cloud con Cloud Storage | Google Cloud](#)

Analizaste algunas preguntas de diagnóstico que abordaron consideraciones relacionadas con el uso de un data lake. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/storage>

<https://cloud.google.com/storage/docs/lifecycle>

<https://cloud.google.com/storage/docs/access-control>

<https://cloud.google.com/storage/docs/audit-logging>

3.4 | Diseño de una malla de datos

Comprende las siguientes consideraciones:

- Creación de una malla de datos basada en requisitos a través de herramientas de Google Cloud (p. ej., Dataplex, Data Catalog, BigQuery, Cloud Storage)
- Segmentación de datos para el uso distribuido de equipos
- Compilación de un modelo de administración federado para sistemas de datos distribuidos

Google Cloud

El concepto de malla de datos se está tornando muy popular hoy en día, ya que las empresas necesitan tener la capacidad de distribuir la propiedad de los datos entre los equipos que controlan el contexto empresarial. Como Professional Data Engineer, deberías poder compilar una malla de datos, segmentar datos para el uso distribuido de equipos y garantizar que la administración general del ciclo de vida de los datos se aplique de manera coherente en todo el entorno de datos distribuido.

En la pregunta 9, se evaluó tu capacidad para crear una malla de datos con herramientas de Google Cloud. En la pregunta 10, se te pidió determinar cómo segmentar y controlar datos para el uso distribuido de equipos.

3.4 | Análisis de la pregunta de diagnóstico 9



Cymbal Retail ha acumulado una gran cantidad de datos. Los analistas y los líderes tienen dificultades para comprender su significado; por ejemplo, las columnas de BigQuery. Los usuarios no saben a quiénes les pertenecen qué datos. Debes mejorar la capacidad de búsqueda de los datos.

- A. Crear etiquetas para entradas de datos en Cloud Catalog
- B. Cambiar el nombre de las columnas de BigQuery por nombres más descriptivos
- C. Exportar los datos a Cloud Storage con nombres de archivo más descriptivos
- D. Agregar una columna de descripción correspondiente a cada columna de datos

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Correcto. Las etiquetas permiten adjuntar metadatos a recursos y entidades de datos. Esto puede mejorar la capacidad de búsqueda de los datos.
- B. Incorrecto. Cambiar el nombre de las columnas de datos no es una opción viable porque podría afectar a otros programas. Los datos también podrían transferirse de fuentes externas en las que no se pueden cambiar los nombres de las columnas.
- C. Incorrecto. Los analistas necesitan los datos en motores de análisis para garantizar el rendimiento y la conveniencia. Transferir los datos a archivos en Cloud Storage no es una buena opción.
- D. Incorrecto. Agregar columnas de descripción para cada columna no es el enfoque conveniente. Aumenta los datos en las tablas y también requiere cambios en los esquemas existentes, ya sea que se definan de manera interna o externa.

Vínculos:

<https://cloud.google.com/data-catalog/docs/tags-and-tag-templates>

<https://cloud.google.com/data-catalog/docs/tag-bigquery-dataset>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Insignia de habilidad:

[Conceptos básicos de Data Catalog](#)

Resumen:

A medida que aumentan los datos, también aumenta el desafío de hacerlos utilizables. El ingeniero de datos puede configurar las maneras de adjuntar metadatos a los datos, automática y manualmente, para aumentar la capacidad de búsqueda de los datos y su comprensión.

3.4 | Análisis de la pregunta de diagnóstico 10



Tienes grandes cantidades de datos almacenados en Cloud Storage y BigQuery. Algunos están procesados, pero otros todavía no lo están. Tienes una malla de datos que se creó en Dataplex. Debes facilitar el proceso de descubrimiento y uso de los datos a los usuarios internos.

¿Qué deberías hacer?

- A. Crear un lake para los datos de Cloud Storage y una zona para los datos de BigQuery
- B. Crear un lake para los datos de BigQuery y una zona para los datos de Cloud Storage
- C. Crear un lake para los datos sin procesar y recursos para los datos procesados
- D. Crear una zona de datos sin procesar para los datos no procesados y una zona de datos seleccionados para los datos procesados

Google Cloud

Comentarios:

- A. Incorrecto. Un lake representa un dominio de datos o una unidad de negocios. Un lake puede abarcar tanto datos en Cloud Storage como en BigQuery.
- B. Incorrecto. Un lake representa un dominio de datos o una unidad de negocios. Un lake puede abarcar tanto datos en Cloud Storage como en BigQuery.
- C. Incorrecto. En una zona, se distingue entre datos procesados y sin procesar.
- D. Correcto. La arquitectura recomendada es usar zonas de datos sin procesar para los datos no procesados y zonas de datos seleccionados para los datos procesados.

Vínculos:

<https://cloud.google.com/dataplex/docs/introduction>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Insignia de habilidad:

[Comienza a usar Dataplex](#)

Resumen:

Dataplex tiene conceptos lógicos que abstraen la tecnología de almacenamiento subyacente. Hay una jerarquía de lakes, zonas, recursos y entidades. Como Professional Data Engineer, usar estos términos de forma coherente y diseñar con ellos hará que la comunicación de las ideas también sea coherente.

3.4 | Diseño de una malla de datos

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Insignias de habilidad

[Conceptos básicos de Data Catalog](#)

[Comienza a usar Dataplex](#)

Documentación

[Etiquetas y plantillas de etiquetas | Documentación de Data Catalog | Google Cloud](#)

[Guía de inicio rápido: Etiqueta una tabla de BigQuery con Data Catalog](#)

[Descripción general de Dataplex | Google Cloud](#)

Analizaste algunas preguntas de diagnóstico que abordaron distintos aspectos sobre el diseño de una malla de datos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

Vínculos:

<https://cloud.google.com/data-catalog/docs/tags-and-tag-templates>

<https://cloud.google.com/data-catalog/docs/tag-bigquery-dataset>

<https://cloud.google.com/dataplex/docs/introduction>