





Cómo prepararte para convertirte en Professional Data Engineer

Módulo 4: Preparación y uso de datos para el análisis

Te damos la bienvenida al Módulo 4: Preparación y uso de datos para el análisis.

Revisión y plan de estudios




Google Cloud

Revisemos cómo usar estas preguntas de diagnóstico para identificar qué incluir en tu plan de estudios.

Recuerda que este curso no está diseñado para enseñarte todo lo que necesitas saber para el examen y que las preguntas de diagnóstico no incluyen todo lo que podría preguntarse en el examen. En su lugar, esta actividad se diseñó para ayudarte a comprender mejor el contenido de la sección y las diferentes habilidades que debes desarrollar en tu preparación para la certificación.

Tu plan de estudios:

Preparación y uso de los datos para el análisis



4.1

Preparación de los datos para su visualización

4.2

Uso compartido de datos

4.3

Exploración y análisis de datos

Google Cloud

En la revisión, verás los objetivos de esta sección del examen y las preguntas que acabas de responder sobre cada uno de ellos. Presentaremos un objetivo, analizaremos brevemente las respuestas a las preguntas relacionadas y explicaremos dónde puedes encontrar más información en los recursos de aprendizaje o en la documentación de Google. A medida que revises el objetivo de cada sección, usa la página de tu cuaderno de ejercicios para marcar la documentación, los cursos y las insignias de habilidad en particular que quieras destacar en tu plan de estudios.

4.1 | Preparación de los datos para su visualización

Comprende las siguientes consideraciones:

- Conexión con las herramientas
- Cálculo previo de los campos
- Vistas materializadas de BigQuery (lógica de vistas)
- Determinación del nivel de detalle de los datos de tiempo
- Solución de problemas de consultas con bajo rendimiento
- Identity and Access Management (IAM) y Cloud Data Loss Prevention (Cloud DLP)

Google Cloud

La visualización eficaz de los datos es fundamental para obtener las estadísticas más valiosas a partir de ellos. Como Professional Data Engineer, trabajarás en varias tareas que prepararán los datos para su visualización. Muchas veces, las consultas subyacentes no son eficientes y, como resultado, la visualización es ineficaz y lenta. Tendrás que implementar técnicas como el cálculo previo de los campos obligatorios antes de que se ejecuten las consultas, la creación de vistas materializadas a partir de tablas de BigQuery y la reducción del nivel de detalle de los datos de tiempo, entre otras.

En la pregunta 1, se evaluaron tus conocimientos sobre la visualización de datos y las herramientas de análisis que pueden conectarse a Google Cloud como fuentes de datos. En la pregunta 2, se evaluó tu habilidad para determinar los flujos de trabajo de los campos calculados previamente para el análisis de datos. En la pregunta 3, se te pidió que diseñaras y crearas vistas para realizar el análisis de datos. En la pregunta 4, se evaluó tu habilidad para determinar el nivel de detalle y la organización de los datos basados en tiempo para su análisis. En la pregunta 5, se te preguntó sobre las prácticas recomendadas para solucionar problemas relacionados con las consultas de bajo rendimiento.

4.1 | Análisis de la pregunta de diagnóstico 1



En tu empresa se usa Google Workspace, y los miembros del equipo de liderazgo están familiarizados con sus apps empresariales y herramientas de colaboración. Quieren una solución rentable que utilice sus conocimientos existentes para evaluar, analizar, filtrar y visualizar datos almacenados en BigQuery.

- A. Crear modelos en Looker
- B. Configurar Hojas conectadas
- C. Configurar Tableau
- D. Configurar Looker Studio

¿Cuál de estas opciones debes elegir para crear una solución para el equipo de liderazgo?

Google Cloud

Comentarios:

- A. Incorrecto. El uso de Looker requiere capacitación adicional para el equipo y genera costos adicionales.
- B. Correcto. Las Hojas conectadas son una forma fácil de integrar los datos de BigQuery en Hojas de cálculo de Google. Debido a que el equipo de liderazgo está familiarizado con Workspace y Hojas de cálculo, esta opción cumple con sus requisitos.
- C. Incorrecto. El uso de Tableau requiere capacitación adicional para el equipo y genera costos adicionales.
- D. Incorrecto. El uso de Looker Studio requiere capacitación adicional para el equipo.

Vínculos:

<https://cloud.google.com/bigquery/docs/data-analysis-tools-intro>

Más información:

Cursos:

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Ingeniería de datos para la transmisión de datos

Resumen:

Google Cloud es compatible con varias herramientas de visualización. Además, puedes integrar herramientas de terceros. Como Professional Data Engineer, debes evaluar las necesidades de la empresa y elegir una herramienta adecuada según el

nivel de experiencia del usuario y otros factores, como el costo. Las Hojas conectadas proporcionan una integración fácil entre Hojas de cálculo de Google y BigQuery, además de análisis y visualización convenientes con herramientas conocidas.

4.1 | Análisis de la pregunta de diagnóstico 2



Tienes datos en PostgreSQL, que se diseñó para disminuir la redundancia. Quieres transferir los datos a BigQuery para realizar análisis. Los datos de origen son jerárquicos y se consultan en conjunto con frecuencia. Necesitas diseñar un esquema de BigQuery con buen rendimiento.

- A. Usar campos anidados y repetidos
- B. Conservar los datos siempre en un formato normalizado
- C. Copiar las tablas principales y usar consultas federadas para las tablas secundarias
- D. Copiar los datos normalizados en particiones

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Correcto. Como los datos se consultan en conjunto, el diseño del esquema puede agrupar los datos con campos anidados y repetidos.
- B. Incorrecto. Los datos normalizados son adecuados para las bases de datos transaccionales, pero no son eficientes para realizar análisis, sobre todo para el tipo de datos que se usan en este caso.
- C. Incorrecto. Las consultas federadas no son eficientes para la analítica, ya que tienen que unir datos de varios sistemas de almacenamiento de datos.
- D. Incorrecto. La ineficiencia de varias tablas normalizadas y separadas permanece incluso si particionas la tabla.

Vínculos:

<https://cloud.google.com/bigquery/docs/best-practices-performance-nested>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

Insignias de habilidad:

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

Un Professional Data Engineer necesita diseñar los esquemas de datos de forma eficiente. El formato normalizado es adecuado para las bases de datos transaccionales, pero no para las bases de datos analíticas. Las uniones toman tiempo. Recopilar los datos relacionados junto con los campos anidados y repetidos puede aumentar la eficacia de la lectura de los datos.

4.1 | Análisis de la pregunta de diagnóstico 3



Ejecutas repetidamente las mismas consultas uniendo varias tablas. Las tablas originales se modifican unas diez veces al día. Quieres un enfoque de consultas optimizado.

- A. Vistas
- B. Vistas materializadas
- C. Consultas federadas
- D. Particiones

¿Qué función deberías usar?

Google Cloud

Comentarios:

- A. Incorrecto. Las vistas vuelven a ejecutar la consulta todas las veces en los datos de origen, por lo que no son una opción óptima.
- B. Correcto. Las vistas materializadas mejorarán el rendimiento de las consultas a través del procesamiento previo y almacenando en caché los resultados de las consultas periódicamente.
- C. Incorrecto. Las consultas federadas no son óptimas porque se usan para consultar los datos que se almacenan fuera de BigQuery.
- D. Incorrecto. Las particiones pueden mejorar el rendimiento de las consultas mediante el análisis de solo una parte de una tabla. Sin embargo, esto puede no ser adecuado para la necesidad empresarial de esta situación.

Vínculos:

<https://cloud.google.com/bigquery/docs/materialized-views-intro>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- [Cómo crear un almacén de datos](#)

Resumen:

A medida que aumentan los volúmenes de datos, la eficiencia del rendimiento se vuelve una consideración importante para los Professional Data Engineers. Tener conocimientos sobre las diversas maneras en que se pueden abstraer los datos

puede ayudarte a determinar el enfoque correcto para los diferentes casos de uso empresariales.

4.1 | Análisis de la pregunta de diagnóstico 4



Tienes datos de estadísticas almacenados en BigQuery. Necesitas una manera eficiente de procesar valores en un grupo de filas y que se devuelva un solo resultado para cada fila.

- A. Usar una función de agregación
- B. Usar una UDF (función definida por el usuario)
- C. Usar BigQuery ML
- D. Usar una función analítica con una cláusula OVER

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Una función de agregación te proporciona un resultado para todas las filas.
- B. Incorrecto. Usar una UDF requiere trabajo adicional, por lo que no es la solución más eficiente.
- C. Incorrecto. BigQuery ML no tiene funciones integradas que proporcionen esta capacidad.
- D. Correcto. Una función analítica define filas en torno a cada fila. Por consiguiente, este enfoque puede producir un resultado separado para cada fila.

Vínculos:

<https://cloud.google.com/bigquery/docs/reference/standard-sql/window-function-calls>

Más información:

Cursos:

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de Dataflow
- Funcionalidad y rendimiento avanzados de BigQuery

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores

Resumen:

BigQuery es una herramienta potente para el análisis compatible con SQL. Tener conocimientos sobre las cláusulas de SQL admitidas es fundamental para los Professional Data Engineers. Las funciones analíticas permiten ahorrar mucho esfuerzo en el análisis de datos que, con otro método, requeriría de consultas complejas.

4.1 | Análisis de la pregunta de diagnóstico 5



Necesitas optimizar el rendimiento de las consultas en BigQuery. Tus tablas no están particionadas ni agrupadas en clústeres.

¿Qué técnica de optimización puedes usar?

- A. Cargar tus inserciones y actualizaciones por lotes
- B. Usar la cláusula LIMIT para reducir la cantidad de datos leídos
- C. Filtrar los datos lo más tarde posible
- D. Realizar uniones de tablas consigo mismas en los datos

Google Cloud

Comentarios:

- A. Correcto. No es conveniente insertar y actualizar filas una por una, es mejor hacerlo por lotes.
- B. Incorrecto. Una cláusula LIMIT se aplica al final de la consulta, lo que causa que no tenga buen rendimiento.
- C. Incorrecto. Filtrar los datos lo antes posible disminuye la cantidad de datos procesados en todas las etapas.
- D. Incorrecto. Las uniones de tablas consigo mismas no tienen buen rendimiento. En su lugar, usa las funciones analíticas.

Vínculos:

<https://cloud.google.com/bigquery/docs/best-practices-performance-compute#avoid-anti-sql-patterns>

https://cloud.google.com/bigquery/docs/best-practices-performance-compute#avoid_self_joins

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Resumen:

El ajuste de rendimiento de BigQuery es una función clave que deben realizar los ingenieros de datos. Debes identificar los cuellos de botella y aplicar varias técnicas de ajuste de rendimiento, como la partición y el agrupamiento en clústeres, las actualizaciones por lotes, la reescritura de consultas para filtrar datos lo antes posible, la prevención de antipatrones de SQL y otras opciones.

4.1

Preparación de los datos para su visualización

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Ingeniería de datos para la transmisión de datos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funciones de transmisión de Dataflow
- Funcionalidad y rendimiento avanzados de BigQuery

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Ventanas, marcas de agua y activadores

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Introducción a las herramientas de análisis y de inteligencia empresarial](#)

[Usa campos anidados y repetidos](#)

[Introducción a las vistas materializadas](#)

[Llamadas a la función analítica](#)

[Optimiza el procesamiento de las consultas](#)

[Optimiza el procesamiento de las consultas](#)

Acabas de analizar varias preguntas de diagnóstico que abordaron distintos aspectos de la preparación de los datos para visualizarlos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en las preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/bigquery/docs/data-analysis-tools-intro>

<https://cloud.google.com/bigquery/docs/best-practices-performance-nested>

<https://cloud.google.com/bigquery/docs/materialized-views-intro>

<https://cloud.google.com/bigquery/docs/reference/standard-sql/window-function-calls>

<https://cloud.google.com/bigquery/docs/best-practices-performance-compute#avoid-anti-sql-patterns>

https://cloud.google.com/bigquery/docs/best-practices-performance-compute#avoid_self_joins

4.2 | Uso compartido de datos

Comprende las siguientes consideraciones:

- Definición de reglas para compartir datos
- Publicación de conjuntos de datos
- Publicación de informes y visualizaciones
- Analytics Hub

Google Cloud

Como Professional Data Engineer, debes saber cómo compartir tus datos con terceros y, además, cómo acceder a los datos que proporcionan ellos y cómo usarlos en tu organización. Google Cloud Analytics Hub es una plataforma de intercambio que te permite intercambiar de forma eficiente y segura datos, modelos de AA y otros recursos analíticos con diferentes organizaciones. Analytics Hub se basa en la escalabilidad y flexibilidad de BigQuery para optimizar la forma en que publicas intercambios de datos, los descubres, te suscribes a ellos y los incorporas en tus análisis. Los datos que se comparten con Analytics Hub incluyen automáticamente administración, encriptación y seguridad avanzadas.

En la pregunta 6, se evaluó tu habilidad para esbozar las reglas para compartir de forma segura datos con las partes interesadas. En la pregunta 7, se evaluó tu nivel de experiencia con las opciones para publicar conjuntos de datos más allá de los límites organizacionales. En la pregunta 8, se evaluó tu nivel de experiencia con las opciones para publicar informes y visualizaciones más allá de los límites organizacionales.

4.2 | Análisis de la pregunta de diagnóstico 6



Tus datos en BigQuery tienen algunas columnas que son sumamente sensibles. Necesitas permitir que solo usuarios determinados vean ciertas columnas.

¿Qué deberías hacer?

- A. Crear un conjunto de datos nuevo con los datos de la columna
- B. Crear una tabla nueva con los datos de la columna
- C. Usar etiquetas de política
- D. Usar permisos de Identity and Access Management (IAM)

Google Cloud

Comentarios:

- A. Incorrecto. Crear un conjunto de datos separado con la columna requerida no es un enfoque viable, ya que los datos originales podrían cambiar.
- B. Incorrecto. Crear una tabla separada con la columna requerida no es un enfoque razonable, ya que los datos originales podrían cambiar.
- C. Correcto. En BigQuery, las etiquetas de política te otorgan control de acceso detallado a nivel de la columna.
- D. Incorrecto. Los permisos de IAM no ofrecen un control de acceso a nivel de la columna con el nivel de detalle requerido para esta situación.

Vínculos:

<https://cloud.google.com/bigquery/docs/column-level-security-intro>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Insignia de habilidad:

[Conceptos básicos de Data Catalog](#)

Resumen:

Para las empresas, es importante controlar el acceso a los datos según quién necesite visualizarlos. Esta tarea está en manos de los Professional Data Engineers, quienes deben conocer los diversos mecanismos de control de acceso. BigQuery, al igual que otros productos de Google Cloud, tiene algunos de sus controles de acceso configurados con IAM. Para obtener un control más detallado, como acceso a nivel de la columna, puedes usar etiquetas de política.

4.2 | Análisis de la pregunta de diagnóstico 7



A lo largo de varios años, en tu empresa han recopilado datos relevantes para la industria. Los datos procesados son útiles para tus socios, quienes están dispuestos a pagar por usarlos. Debes asegurarte de implementar el control de acceso adecuado sobre los datos.

- A. Exportar los datos a archivos ZIP y compartirlos a través de Cloud Storage
- B. Alojarse los datos en Analytics Hub
- C. Exportar los datos a discos persistentes y compartirlos a través de un extremo de FTP
- D. Alojarse los datos en Cloud SQL

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Cloud Storage no proporciona el mejor control del acceso externo a los datos para compartirlos, y la monetización deberá realizarse de forma separada.
- B. Correcto. Analytics Hub tiene opciones integradas para conectar a los publicadores y suscriptores con control de acceso y para monetizar el acceso a los datos.
- C. Incorrecto. Compartir datos a través de extremos de FTP ofrece un control de acceso muy limitado y no se recomienda.
- D. Incorrecto. Cloud SQL no proporciona un control de acceso conveniente ni opciones integradas de monetización.

Vínculos:

<https://cloud.google.com/analytics-hub>

<https://cloud.google.com/bigquery/docs/analytics-hub-introduction>

<https://www.youtube.com/watch?v=KOzo1tkScTs>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Resumen:

Analytics Hub es una herramienta conveniente para compartir datos con socios. Los ingenieros de datos tendrán control sobre lo que las personas pueden hacer con sus datos. Analytics Hub también puede convertir un centro de costos en un centro de ganancias con la monetización de datos.

4.2 | Análisis de la pregunta de diagnóstico 8



Tienes un conjunto complejo de datos que provienen de múltiples fuentes. Los analistas de tu equipo necesitan estudiar los datos, visualizarlos y publicar informes para las partes interesadas internas y externas. Debes facilitarles a los analistas trabajar con los datos abstrayendo las múltiples fuentes de datos.

- A. Looker Studio
- B. Hojas conectadas
- C. Biblioteca D3.js
- D. Looker

¿Qué herramientas recomendarías?

Google Cloud

Comentarios:

- A. Incorrecto. Looker Studio (antes llamado Data Studio) es una herramienta de visualización que no tiene las capacidades de abstracción de datos del modelado de Looker.
- B. Incorrecto. Las Hojas conectadas te otorgan acceso a los datos en BigQuery, pero no a otras fuentes de datos.
- C. Incorrecto. Para usar la biblioteca D3.js, los analistas deben tener mucha experiencia en JavaScript y con los complejos detalles de la creación de visualizaciones con la biblioteca. Por lo general, esto no es factible para los analistas.
- D. Correcto. Looker te permite modelar las fuentes de datos subyacentes y crear una abstracción que los analistas pueden utilizar como base fácilmente.

Vínculos:

<https://cloud.google.com/looker>

Más información:

Cursos:

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Ingeniería de datos para la transmisión de datos

Resumen:

Google Cloud cuenta con una amplia variedad de opciones de visualización, que los ingenieros de datos pueden elegir según el nivel de complejidad con el que los

usuarios quieren lidiar. La familia de productos de visualización de Looker ofrece facilidad de uso que se basa en tablas simples y, también, datos complejos de varias fuentes que se pueden abstraer para los usuarios finales.

4.2 | Uso compartido de datos

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Ingeniería de datos para la transmisión de datos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Insignias de habilidad

[Conceptos básicos de Data Catalog](#)

Documentación

[Introducción al control de acceso a nivel de columna](#)

[Analytics Hub | Intercambio y uso compartido de datos | Google Cloud](#)

[Introducción a Analytics Hub | BigQuery](#)

[Protege los intercambios de datos y el uso compartido de datos con Analytics Hub](#)

[Looker, plataforma de inteligencia empresarial y análisis incorporados](#)

En las preguntas de diagnóstico que acabas de revisar, se abordaron algunos aspectos de la planificación para compartir datos. Estos son algunos cursos y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/bigquery/docs/column-level-security-intro>

<https://cloud.google.com/analytics-hub>

<https://cloud.google.com/bigquery/docs/analytics-hub-introduction>

<https://www.youtube.com/watch?v=KOzo1tkScTs>

<https://cloud.google.com/looker>

4.3 | Exploración y análisis de datos

Comprende las siguientes consideraciones:

- Preparación de datos para la ingeniería de atributos (entrenamiento y entrega de modelos de aprendizaje automático)
- Realización del descubrimiento de datos

Google Cloud

Como Professional Data Engineer, trabajarás estrechamente con ingenieros de aprendizaje automático y les proporcionarás los datos necesarios para que creen modelos de AA. Estos deben procesarse para que los ingenieros de AA puedan llevar a cabo la ingeniería de atributos, a la vez que entrenan y entregan modelos de aprendizaje automático.

En la pregunta 9, se te pidió que describieras el proceso de la ingeniería de atributos y que explicaras cómo respalda los flujos de trabajo de aprendizaje automático. En la pregunta 10, se evaluaron tus conocimientos sobre cómo se respalda el acceso a los datos y el descubrimiento de estos para los flujos de trabajo de aprendizaje automático.

4.3 | Análisis de la pregunta de diagnóstico 9



Creaste modelos de aprendizaje automático (AA) basados en tus datos.

En la etapa de producción, los modelos de AA no están dando resultados satisfactorios.

Cuando examinas los datos, te parece que no representan lo suficiente los objetivos comerciales. Debes crear un modelo de aprendizaje automático más preciso.

- A. Entrenar el modelo con más datos similares
- B. Llevar a cabo la regularización L2
- C. Llevar a cabo la ingeniería de atributos y usar los conocimientos sobre el dominio para mejorar los datos de las columnas.
- D. Entrenar el modelo con los mismos datos, pero usando más ciclos de entrenamiento

¿Qué deberías hacer?

Google Cloud

Comentarios:

A: Incorrecto. El tipo de datos parece ser insuficiente para representar el requisito empresarial. Tener más datos del mismo tipo no sería una ayuda.

B: Incorrecto. Al parecer, el sobreajuste no es el problema. Por lo tanto, la regularización L2 no mejorará las predicciones del modelo.

C: Correcto. Con la ingeniería de atributos, se pueden elegir las columnas de datos relevantes y, además, mejorar el modelo combinando columnas. Para este requisito, la ingeniería de atributos mejora el modelo de AA.

D: Incorrecto. Puede que repetir el entrenamiento durante más tiempo con los mismos datos no mejore el modelo.

Vínculos:

<https://cloud.google.com/bigquery/docs/bigqueryml-transform>

<https://cloud.google.com/bigquery/docs/preprocess-overview>

Más información:

Cursos:

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Macrodatos con BigQuery
- Flujo de trabajo del aprendizaje automático con Vertex AI

[Analítica inteligente, IA y aprendizaje automático en Google Cloud](#)

- Creación de modelos personalizados con SQL en BigQuery ML

Insignia de habilidad:

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

El aprendizaje automático es vital para las empresas. Sin embargo, obtener resultados satisfactorios requiere ajustar el modelo de diversas maneras. Los Professional Data Engineers pueden mejorar el rendimiento del modelo con técnicas como la ingeniería de atributos, con la que tú eliges las columnas pertinentes y las combinas para que los datos sean relevantes.

4.3 | Análisis de la pregunta de diagnóstico 10



Usaste Dataplex para crear lakes y zonas para tus datos empresariales. Sin embargo, algunos archivos no se descubren.

¿Cuál podría ser el problema?

- A. Tienes un patrón de exclusión que coincide con los archivos.
- B. Programaste el descubrimiento para que se ejecute cada hora.
- C. Los archivos están en formato ORC.
- D. Los archivos están en formato Parquet.

Google Cloud

Comentarios:

A: Correcto. Con un patrón de exclusión, se omite el archivo y, por lo tanto, ese podría ser el motivo por el que los datos no se descubran.

B: Incorrecto. Incluso si el descubrimiento se ejecuta solo cada hora, los archivos deberían descubrirse en algún momento, lo que no ocurre en este caso. Por lo tanto, ese no es el problema.

C: Incorrecto. Se admite el formato ORC, por lo que el archivo debería descubrirse.

D: Incorrecto. Se admite el formato Parquet, por lo que el archivo debería descubrirse.

Vínculos:

<https://cloud.google.com/dataplex/docs/discover-data>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

Resumen:

Dataplex puede descubrir y catalogar datos automáticamente en ciertos formatos de archivo. Sin embargo, tú controlas qué archivos pueden descubrirse y puedes

configurar patrones de exclusión para ignorar intencionalmente ciertos datos.

4.3 Exploración y análisis de datos

Cursos

[Conceptos básicos de Google Cloud: macrodatos y aprendizaje automático](#)

- Macrodatos con BigQuery
- Flujo de trabajo del aprendizaje automático con Vertex AI

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Introducción a la creación de canalizaciones de datos por lotes

[Analítica inteligente, IA y aprendizaje automático en Google Cloud](#)

- Creación de modelos personalizados con SQL en BigQuery ML

Insignias de habilidad

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Realizar ingeniería de atributos con la cláusula TRANSFORM | BigQuery ML | Google Cloud](#)

[Descripción general del procesamiento previo de atributos | BigQuery | Google Cloud](#)

[Descubrimiento de datos | Dataplex | Google Cloud](#)

Analizaste algunas preguntas de diagnóstico que abordaron consideraciones relacionadas con el uso de un data lake. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en las preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/bigquery/docs/bigqueryml-transform>

<https://cloud.google.com/bigquery/docs/preprocess-overview>

<https://cloud.google.com/dataplex/docs/discover-data>