





Cómo prepararte para convertirte en Professional Data Engineer

Módulo 5: Mantenimiento y automatización
de cargas de trabajo de datos

Te damos la bienvenida al Módulo 5: Mantenimiento y automatización de cargas de trabajo de datos.

Revisión y plan de estudios




Google Cloud

Revisemos cómo usar estas preguntas de diagnóstico para identificar qué incluir en tu plan de estudios.

Recuerda que este curso no está diseñado para enseñarte todo lo que necesitas saber para el examen y que las preguntas de diagnóstico no incluyen todo lo que podría preguntarse en el examen. En su lugar, esta actividad se diseñó para ayudarte a comprender mejor el contenido de la sección y las diferentes habilidades que debes desarrollar en tu preparación para la certificación.

Tu plan de estudios:

Mantenimiento y automatización de las cargas de trabajo de datos



5.1

Optimización de recursos

5.2

Diseño de automatización y repetibilidad

5.3

Organización de las cargas de trabajo según los requisitos empresariales

5.4

Procesos de supervisión y solución de problemas

5.5

Reconocimiento de las fallas y mitigación del impacto

Google Cloud

En la revisión, verás los objetivos de esta sección del examen y las preguntas que acabas de responder sobre cada uno de ellos. Presentaremos un objetivo, revisaremos brevemente las respuestas a las preguntas relacionadas y explicaremos dónde puedes encontrar más información en los recursos de aprendizaje o en la documentación de Google. A medida que revises el objetivo de cada sección, usa la página de tu cuaderno de ejercicios para marcar la documentación, los cursos y las insignias de habilidad en particular que quieras destacar en tu plan de estudios.

5.1 | Optimización de recursos

Comprende las siguientes consideraciones:

- Minimizar los costos por la necesidad empresarial de datos
- Garantizar que haya suficientes recursos disponibles para los procesos de datos fundamentales de la empresa
- Decidir entre clústeres de datos persistentes o basados en trabajos (p. ej., Dataproc)

Google Cloud

Como Professional Data Engineer, debes aprovisionar suficientes recursos para cumplir los requisitos de rendimiento de diferentes procesos de datos. Pero, al mismo tiempo, debes minimizar los costos que están asociados con estos recursos. Una manera de minimizar el costo es decidir si deseas recursos persistentes o basados en trabajos. Los recursos persistentes garantizan la capacidad de procesamiento, pero debes pagar un precio fijo, independientemente del uso real. Por otro lado, los recursos basados en trabajos proporcionan flexibilidad para crear clústeres solo cuando son necesarios y, por lo tanto, se paga según el uso real.

En la pregunta 1, se evaluaron tus conocimientos de las opciones y consideraciones para decidir entre recursos persistentes y basados en trabajos.

5.1 | Análisis de la pregunta de diagnóstico 1



Necesitas diseñar un clúster de Dataproc para ejecutar varios trabajos pequeños. Muchos trabajos son de prioridad alta, pero no todos.

¿Qué deberías hacer?

- A. Volver a usar el mismo clúster y ejecutar cada trabajo en secuencia
- B. Volver a usar el mismo clúster para ejecutar todos los trabajos en paralelo
- C. Usar clústeres efímeros
- D. Usar el escalado automático de clústeres

Google Cloud

Comentarios:

- A. Incorrecto. Debido a que muchos trabajos son de prioridad alta, ejecutarlos en secuencia no cumpliría con los requisitos de negocio.
- B. Incorrecto. Con Dataproc, este no es el enfoque recomendado. Las configuraciones y los trabajos en ejecución podrían interferir entre sí.
- C. Correcto. Los trabajos pueden usar clústeres efímeros para ejecutar rápidamente el trabajo y, después del uso, cancelar la asignación de los recursos. Varios trabajos pueden ejecutarse en paralelo sin interferir unos con otros.
- D. Incorrecto. El escalado automático de clústeres es eficaz en un clúster que ejecuta trabajos individuales, pero no se recomienda cuando se ejecutan varios trabajos debido a que pueden interferir en el escalamiento de recursos.

Vínculos:

<https://cloud.google.com/blog/products/data-analytics/dataproc-job-optimization-how-to-guide>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

Resumen:

La elasticidad de Google Cloud hace que sea conveniente para asignar y cancelar la

asignación de recursos rápidamente. Cada trabajo puede aislarse de los demás para evitar interferencias. El ingeniero de datos o de infraestructura también puede transferir la administración de recursos a Google Cloud.

5.1 | Optimización de recursos

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

Documentación

[Guía práctica para la optimización de trabajos de Dataproc | Blog de Google Cloud](#)

Acabas de revisar una pregunta de diagnóstico relacionada con algunos aspectos de la optimización de recursos. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/blog/products/data-analytics/dataproc-job-optimization-how-to-guide>

5.2 | Diseño de automatización y repetibilidad

Comprende las siguientes consideraciones:

- Creación de grafos acíclicos dirigidos (DAG) para Cloud Composer
- Programación de trabajos repetibles

Google Cloud

Como Professional Data Engineer, trabajarás para aumentar la productividad a través de la automatización de cargas de trabajo repetibles. Debes conocer Cloud Composer por completo, un servicio de organización del flujo de trabajo completamente administrado y basado en Apache Airflow que te da la posibilidad de crear, programar y supervisar tus flujos de trabajo. Cloud Composer te permite configurar las canalizaciones como grafos acíclicos dirigidos (DAG) con Python.

En la pregunta 2, se te pidió describir cómo los grafos acíclicos dirigidos (DAG) admiten la automatización y la repetibilidad de las cargas de trabajo.

5.2 | Análisis de la pregunta de diagnóstico 2



Tienes que crear tareas repetitivas de procesamiento de datos a través de Cloud Composer. Debes seguir las prácticas y los enfoques recomendados.

¿Qué deberías hacer?

- A. Definir cada tarea como responsable de una operación
- B. Usar la hora actual con la función `now()` para el procesamiento
- C. Actualizar los datos con las sentencias `INSERT` durante la ejecución de la tarea
- D. Combinar varias funcionalidades en una sola ejecución de tarea

Google Cloud

Comentarios:

- A. Correcto. Para ejecutar tareas repetitivas, se recomienda usar tareas atómicas que tengan una sola responsabilidad. Muchas de estas tareas pueden combinarse en secuencia para lograr un resultado final deseado.
- B. Incorrecto. Usar la hora actual para el procesamiento de datos genera ejecuciones de tareas diferentes y no repetitivas.
- C. Incorrecto. Insertar instrucciones en las tareas crea nuevas entradas. Volver a ejecutar las mismas tareas insertará entradas nuevas otra vez. En lugar de `INSERT`, debería usarse `UPSERT`.
- D. Incorrecto. Se recomienda que una sola tarea ocupe una sola funcionalidad.

Vínculos:

<https://cloud.google.com/composer/docs/how-to/using/writing-dags>
<https://airflow.apache.org/docs/apache-airflow/stable/core-concepts/dags.html>
<https://docs.astronomer.io/learn/dag-best-practices>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

Insignia de habilidad:

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Resumen:

Se prefiere la creación de tareas idempotentes y repetitivas en las canalizaciones de datos. El ingeniero de datos debe diseñar toda la canalización de datos como una serie de tareas atómicas componibles. En el caso de Cloud Composer, puedes crear DAG (grafos acíclicos dirigidos) que vinculan tareas idempotentes y atómicas en una canalización de procesamiento que se convertirá en repetitiva.

5.2 | Diseño de automatización y repetibilidad

Cursos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Administra canalizaciones de datos con Cloud Data Fusion y Cloud Composer

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

Insignias de habilidad

[Ingeniería de datos para crear modelos predictivos con BigQuery ML](#)

Documentación

[Escribe DAG de Airflow | Cloud Composer](#)

[DAG — Documentación de Airflow](#)

[Prácticas recomendadas para escribir DAG en Apache Airflow | Documentación de Astronomer](#)

En la pregunta de diagnóstico que acabas de revisar, se abordaron algunos aspectos del diseño de automatización y repetibilidad. Estos son algunos cursos y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/composer/docs/how-to/using/writing-dags>

<https://airflow.apache.org/docs/apache-airflow/stable/core-concepts/dags.html>

<https://docs.astronomer.io/learn/dag-best-practices>

5.3 | Organización de las cargas de trabajo según los requisitos empresariales

Comprende las siguientes consideraciones:

- Precios de ranuras flexibles, a pedido y de tarifa plana (índice sobre la flexibilidad o capacidad fija)
- Trabajos de consulta interactiva o por lotes

Google Cloud

Como Professional Data Engineer, debes conocer los diferentes modelos de precios para varios servicios de Google Cloud y deberías poder seleccionar el modelo de precios adecuado según el caso de uso empresarial. Por ejemplo, BigQuery te permite seleccionar entre modelos de precios a pedido, de tarifa plana y flexibles. Con el modelo de precios a pedido, solo pagas por lo que consumes. El modelo de precios de tarifa plana proporciona recursos exclusivos y los precios flexibles te permiten aumentar la capacidad existente durante un período breve.

En la pregunta 3, se te pidió diferenciar entre las opciones de ranuras de BigQuery para organizar y ejecutar cargas de trabajo según los requisitos de negocio. En la pregunta 4, se te pidió diferenciar entre trabajos de consulta interactiva y por lotes en BigQuery para organizar y ejecutar cargas de trabajo según los requisitos de negocio.

5.3 | Análisis de la pregunta de diagnóstico 3



Varios analistas deben preparar informes los lunes por la mañana, por lo que BigQuery se utiliza mucho. Quieres adoptar un enfoque rentable para administrar esta demanda.

¿Qué deberías hacer?

- A. Usar precios a pedido
- B. Usar ranuras flexibles
- C. Usar la edición Enterprise de BigQuery con un compromiso por un año
- D. Usar la edición Enterprise Plus de BigQuery con un compromiso por tres años

Google Cloud

Comentarios:

- A. Incorrecto. Los precios a pedido no son rentables para esta situación.
- B. Correcto. Las ranuras flexibles te permiten reservar ranuras de BigQuery durante períodos breves.
- C. Incorrecto. Dada la duración de la demanda, no se necesita un compromiso de un año.
- D. Incorrecto. Un compromiso de varios años no es necesario dada la duración de la demanda.

Vínculos:

<https://cloud.google.com/blog/products/data-analytics/introducing-bigquery-flex-slots>
<https://cloud.google.com/bigquery/docs/reservations-intro>
<https://cloud.google.com/bigquery/docs/editions-intro>

Más información:

Cursos:

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Resumen:

BigQuery tiene una variedad de opciones para precios de consultas, lo que incluye compromisos a largo plazo, reservas a corto plazo y precios a pedido. Para controlar los costos, un Professional Data Engineer puede elegir la opción adecuada durante la demanda de análisis.

5.3 | Análisis de la pregunta de diagnóstico 4



Tienes un equipo de analistas de datos que ejecutan consultas de manera interactiva en BigQuery durante el horario laboral. También tienes miles de consultas de generación de informes que se ejecutan de manera simultánea. A menudo aparece un error: *Se excedieron los límites de frecuencia: muchas consultas simultáneas para este project_and_region.*

- A. Ejecutar todas las consultas en modo interactivo
- B. Crear una reserva anual de ranuras de BigQuery
- C. Ejecutar las consultas de generación de informes en el modo por lotes
- D. Crear una vista para ejecutar las consultas

¿Cómo resolverías el problema?

Google Cloud

Comentarios:

- A. Incorrecto. Ejecutar todas las consultas en modo interactivo generaría el mismo error.
- B. Incorrecto. Reservar ranuras de BigQuery no evitará el error porque se seguirán aplicando los límites de consultas simultáneas.
- C. Correcto. Transferir las consultas de generación de informes al modo por lotes reduce la cantidad de consultas simultáneas.
- D. Incorrecto. Las consultas ejecutadas en vistas también se tienen en cuenta para el límite de consultas simultáneas y, por lo tanto, no resuelven este problema.

Vínculos:

<https://cloud.google.com/bigquery/docs/running-queries>

<https://cloud.google.com/bigquery/docs/troubleshoot-quotas#ts-concurrent-queries-quota>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un almacén de datos

Resumen:

Google Cloud tiene cuotas y establece límites en torno al uso de determinados recursos. En algunos casos, tu equipo puede solicitar aumentos en estas cuotas y límites. En otros casos, son fijos. Un Professional Data Engineer debe conocer estos límites para garantizar la disponibilidad de los servicios a sus equipos internos. A diferencia de las consultas interactivas, las consultas por lotes no se tienen en cuenta para el límite de simultaneidad. BigQuery ejecuta las consultas por lotes cuando hay recursos inactivos disponibles, lo que, por lo general, toma unos minutos.

5.3 Organización de las cargas de trabajo según los requisitos empresariales

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos
- Cómo crear un almacén de datos

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Funcionalidad y rendimiento avanzados de BigQuery

Documentación

[Escala y reduce la escala verticalmente de un almacén de datos en la nube con rapidez](#)

[Introducción a las reservas | BigQuery | Google Cloud](#)

[Introducción a las ediciones de BigQuery | Google Cloud](#)

[Ejecuta una consulta | BigQuery | Google Cloud](#)

[Soluciona problemas de cuota y de límite | BigQuery | Google Cloud](#)

En las preguntas de diagnóstico que acabas de revisar, se abordaban consideraciones relacionadas con la organización de las cargas de trabajo según los requisitos de negocio. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/blog/products/data-analytics/introducing-bigquery-flex-slots>

<https://cloud.google.com/bigquery/docs/reservations-intro>

<https://cloud.google.com/bigquery/docs/editions-intro>

5.4 | Procesos de supervisión y solución de problemas

Comprende las siguientes consideraciones:

- Observabilidad de los procesos de datos (p. ej., Cloud Monitoring, Cloud Logging y el panel de administración de BigQuery)
- Supervisión del uso planificado
- Solución de problemas de mensajes de error, problemas de facturación y cuotas
- Administración de cargas de trabajo, como trabajos, consultas y capacidad de procesamiento (reservas)

Google Cloud

Una vez que hayas automatizado las cargas de trabajo, es muy importante que las supervises de manera constante y adoptes una medida correctiva rápida si se produce algún error. Google Cloud ofrece Cloud Monitoring, un servicio para obtener visibilidad del rendimiento, la disponibilidad y el estado de las aplicaciones y la infraestructura. Ofrece paneles de recopilación automática de métricas listos para usar y la posibilidad de configurar alertas con reglas complejas. También debes conocer otras herramientas para supervisar y solucionar problemas, como Cloud Logging y el panel de administración de BigQuery.

En la pregunta 5, se evaluaron tus conocimientos respecto de la supervisión de flujos de trabajo de datos activos y planificados. En la pregunta 6, se evaluaron tus conocimientos respecto de la manera para supervisar y solucionar problemas resultantes de las cargas de trabajo de datos. En la pregunta 7, se evaluó tu nivel de experiencia con las opciones para administrar operaciones de cargas de trabajo de datos y capacidad de procesamiento.

5.4 | Análisis de la pregunta de diagnóstico 5



Tienes una canalización de Dataflow en producción. Para determinados datos, el sistema parece atascarse más de lo habitual, lo que provoca retrasos en la ejecución de la canalización. Quieres hacer un seguimiento de dichos problemas y resolverlos de manera confiable y proactiva.

¿Qué deberías hacer?

- A. Revisar los registros de Dataflow con regularidad
- B. Configurar alertas con el código de Cloud Run Functions que revisa los registros de auditoría con regularidad
- C. Revisar el panel de Cloud Monitoring con regularidad
- D. Configurar alertas en Cloud Monitoring según el retraso del sistema

Google Cloud

Comentarios:

- A. Incorrecto. Identificar retrasos en los registros de Dataflow no es una solución viable ni confiable.
- B. Incorrecto. Los registros de auditoría no muestran información como, por ejemplo, un retraso del sistema de canalización de Dataflow. Escribir código para revisar registros y enviar alertas es un proceso complicado y no se recomienda.
- C. Incorrecto. Detectar demoras en el panel de supervisión no es una solución viable ni confiable.
- D. Correcto. Configurar alertas notifica de manera proactiva a los usuarios sobre los problemas o las métricas que deben rastrearse.

Vínculos:

<https://cloud.google.com/dataflow/docs/guides/using-cloud-monitoring>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub
- Funcionalidad y rendimiento avanzados de BigQuery

Procesamiento de datos sin servidores con Dataflow: Operaciones

- Supervisión
- Solución de problemas y depuración

Resumen:

Podría haber muchos más recursos en tu entorno de nube. Hacer un seguimiento de todos ellos o detectar cambios en los registros o el panel no es una opción práctica. En cambio, el ingeniero de datos puede configurar notificaciones críticas que informarán al usuario sobre los umbrales alcanzados.

5.4 | Análisis de la pregunta de diagnóstico 6



Cuando ejecutas trabajos de Dataflow, ves este error en los registros: *"Se detectó una clave activa HOT_KEY_NAME en..."*. Necesitas resolver este problema y mejorar el rendimiento de la carga de trabajo.

- A. Inhabilitar Dataflow Shuffle
- B. Aumentar los datos con la clave activa
- C. Garantizar que los datos estén distribuidos de manera uniforme
- D. Agregar más instancias de procesamiento para procesar

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. Se recomienda habilitar Dataflow Shuffle porque particiona y agrupa datos por clave de manera escalable, eficiente y tolerante a errores.
- B. Incorrecto. Aumentar la cantidad de datos con la misma clave activa incrementará los hotspots, lo que hará menos eficiente el procesamiento de datos.
- C. Correcto. Las transformaciones de Dataflow tienen mejor rendimiento con una clave distribuida de forma uniforme.
- D. Incorrecto. Agregar más instancias de procesamiento no resuelve automáticamente los hotspots en los datos.

Vínculos:

<https://cloud.google.com/dataflow/docs/guides/common-errors#hot-key-detected>
<https://cloud.google.com/dataflow/docs/guides/troubleshoot-stragglers>

Más información:

Cursos:

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- IAM, cuotas y permisos

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Estado y temporizadores
- Prácticas recomendadas

Procesamiento de datos sin servidores con Dataflow: Operaciones

- Solución de problemas y depuración
- Confiabilidad

Resumen:

Por lo general, el rendimiento de los grandes algoritmos y sistemas de procesamiento de datos se ve afectado de manera negativa por claves que se agrupan en un pequeño intervalo lexicográfico. Un Professional Data Engineer debería poder solucionar problemas a través de la interpretación de errores, el examen de registros y la supervisión de entornos de nube. En este caso, se puede deducir del error que se trata de un problema de clave activa y se puede mejorar el rendimiento del procesamiento si se cambia la clave de los datos y se garantiza que se distribuyan de manera más uniforme.

5.4 | Análisis de la pregunta de diagnóstico 7



Un colega de Cymbal Retail te pregunta sobre la configuración del escalado automático de Dataproc para un proyecto.

¿En qué situación Google recomienda la habilitación del escalado automático?

- A. Cuando deseas escalar el sistema de archivos distribuidos de Hadoop (HDFS) en el clúster
- B. Cuando deseas escalar horizontalmente clústeres de un solo trabajo
- C. Cuando deseas reducir la escala verticalmente de los clústeres inactivos al tamaño mínimo
- D. Cuando hay cargas de trabajo de diferente tamaño en el clúster

Google Cloud

Comentarios:

- A. Incorrecto. Debido a que el uso de HDFS no es un indicador para el escalado automático, este no sería un buen caso de uso.
- B. Correcto. Los clústeres de un solo trabajo son excelentes para el escalado automático porque no habrá ninguna superposición con el escalamiento de otros trabajos.
- C. Incorrecto. En Dataproc, se recomienda que borres los clústeres inactivos en lugar de reducir la escala verticalmente al tamaño mínimo, ya que resulta rápido y rentable.
- D. Incorrecto. Ejecutar cargas de trabajo de diferente tamaño en el mismo clúster puede provocar interferencia. Los trabajos de larga duración pueden interferir en la reducción de escala de los trabajos más pequeños y retrasarla.

Vínculos:

<https://cloud.google.com/dataflow/docs/guides/common-errors#hot-key-detected>
<https://cloud.google.com/dataflow/docs/guides/troubleshoot-stragglers>

Más información:

Cursos:

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

Insignia de habilidad:

[Prepara datos para las APIs de AA en Google Cloud](#)

Resumen:

El escalado automático en Google Cloud te permite transferir la tarea de administración de escalamiento de la infraestructura a Google Cloud. Sin embargo, conlleva ciertas advertencias. Determinados tipos de trabajos de Dataproc son más adecuados para el escalado automático que otros. En algunos casos, podría ser preferible inhabilitar el escalado automático y usar otros enfoques para detener y borrar los clústeres.

5.4 Procesos de supervisión y solución de problemas

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Introducción a la ingeniería de datos

[Crea canalizaciones de datos por lotes en Google Cloud](#)

- Ejecuta Spark en Dataproc

[Crea sistemas resilientes de análisis de transmisiones en Google Cloud](#)

- Mensajería sin servidores con Pub/Sub
- Funcionalidad y rendimiento avanzados de BigQuery

[Procesamiento de datos sin servidores con Dataflow: Fundamentos](#)

- IAM, cuotas y permisos

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Estado y temporizadores
- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Supervisión
- Solución de problemas y depuración
- Confiabilidad

Insignias de habilidad

[Prepara datos para las APIs de AA en Google Cloud](#)

Documentación

[Usa Cloud Monitoring para las canalizaciones de Dataflow](#)

[Soluciona errores de Dataflow | Google Cloud](#)

[Soluciona problemas de demora en trabajos por lotes | Cloud Dataflow](#)

[Escalado automático de clústeres |](#)

[Documentación de Dataproc | Google Cloud](#)

Acabas de revisar varias preguntas de diagnóstico que abordaron consideraciones relacionadas con la supervisión y la solución de problemas. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/dataflow/docs/guides/using-cloud-monitoring>

<https://cloud.google.com/dataflow/docs/guides/common-errors#hot-key-detected>

<https://cloud.google.com/dataflow/docs/guides/troubleshoot-stragglers>

<https://cloud.google.com/dataproc/docs/concepts/configuring-clusters/autoscaling>

5.5 Reconocimiento de las fallas y mitigación del impacto

Comprende las siguientes consideraciones:

- Diseño del sistema para la tolerancia a errores y administración de reinicios
- Ejecución de trabajos en varias regiones o zonas
- Preparación para la corrupción de datos y los datos faltantes
- Replicación de datos y conmutación por error (p. ej., Cloud SQL y clústeres de Redis)

Google Cloud

Como Professional Data Engineer, deberías poder garantizar la continuidad del proceso incluso cuando se produce alguna falla. Google Cloud ofrece varias opciones que usan la redundancia para crear sistemas tolerantes a errores. Por ejemplo, puedes almacenar tus datos en varias zonas y regiones y, por lo tanto, mejorar la disponibilidad de los datos. O, cuando uses un servicio de almacenamiento como Cloud SQL, puedes activar la replicación de datos y la conmutación por error automática.

En la pregunta 8, se evaluó tu conocimiento sobre cómo ejecutar trabajos en varias regiones y zonas para admitir la tolerancia a errores. En la pregunta 9, se evaluó tu capacidad para determinar estrategias para la replicación de datos y la conmutación por error. En la pregunta 10, se evaluó tu nivel de experiencia con las opciones para manejar datos dañados y faltantes.

5.5 | Análisis de la pregunta de diagnóstico 8



Cymbal Retail procesa datos de transmisión en Dataflow con Pub/Sub como fuente. Necesitas planificar la recuperación ante desastres y brindar protección contra fallas zonales.

- A. Crear instantáneas de Dataflow de forma periódica
- B. Crear trabajos de Dataflow a partir de plantillas
- C. Habilitar el escalado automático vertical
- D. Habilitar Dataflow Shuffle

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Correcto. Cuando se ejecutan canalizaciones de transmisión, las instantáneas de Dataflow pueden guardar el estado actual. Luego, puedes iniciar un nuevo trabajo según el estado guardado. Esto te permite recuperarte de fallas y también migrar trabajos.
- B. Incorrecto. Crear trabajos a partir de plantillas facilita el inicio de nuevos trabajos a través del cambio de los valores de parámetros. Sin embargo, dado que las plantillas no conservan ningún estado, no son útiles para la recuperación ante desastres.
- C. Incorrecto. El escalado automático vertical puede asignar capacidad de procesamiento de manera dinámica en función del uso del trabajador, pero no es relevante para la recuperación ante desastres.
- D. Incorrecto. El escalado automático horizontal puede cambiar automáticamente la cantidad de trabajadores asignados a tu trabajo, pero no es relevante para la recuperación ante desastres.

Vínculos:

<https://cloud.google.com/dataflow/docs/guides/using-snapshots>

Más información:

Cursos:

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Prácticas recomendadas

Procesamiento de datos sin servidores con Dataflow: Operaciones

- Confiabilidad

Resumen:

Muchos tipos de fallas ocurren en cualquier sistema. El ingeniero de datos no solo tiene que diseñar sistemas para mitigar esas fallas; también elaborar un plan para fallas catastróficas. La planificación de recuperación ante desastres tiene en cuenta tus objetivos comerciales como RPO (objetivo de punto de recuperación), RTO (objetivo de tiempo de recuperación) y los costos. En Dataflow, tomar instantáneas periódicas te puede ayudar a recuperarte de una falla catastrófica y reiniciar los trabajos desde el estado guardado.

5.5 | Análisis de la pregunta de diagnóstico 9



Ejecutas una instancia de Cloud SQL de una empresa que requiere que la base de datos sea accesible para realizar transacciones. Necesitas garantizar que el tiempo de inactividad sea mínimo para las transacciones de la base de datos.

- A. Configurar la replicación
- B. Configurar la alta disponibilidad
- C. Configurar las copias de seguridad
- D. Configurar las copias de seguridad y aumentar la cantidad de copias de seguridad

¿Qué deberías hacer?

Google Cloud

Comentarios:

- A. Incorrecto. La replicación en Cloud SQL es eficaz para transferir operaciones de lectura. Sin embargo, no admite una base de datos de lectura/escritura completa.
- B. Correcto. La configuración de la alta disponibilidad en Cloud SQL cambiará automáticamente a la instancia secundaria cuando la instancia principal falle, lo que reduce el tiempo de inactividad para los usuarios de la base de datos.
- C. Incorrecto. Las copias de seguridad son útiles para recuperar datos más antiguos en caso de fallas catastróficas, como la eliminación accidental de datos. Sin embargo, no proporcionan una disponibilidad continua de la base de datos, ya que su restablecimiento toma tiempo.
- D. Incorrecto. Aumentar la cantidad de copias de seguridad no afecta ni mejora la disponibilidad. Aunque existan más copias de seguridad, restablecer la base de datos en caso de fallas generaría tiempo de inactividad.

Vínculos:

<https://cloud.google.com/sql/docs/mysql/high-availability>

Más información:

Cursos:

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

Resumen:

La configuración de alta disponibilidad de Cloud SQL tiene una instancia principal y una secundaria. Las actualizaciones de datos pueden verse en ambas instancias. Si se produce una falla en la base de datos, el ingeniero responsable no tiene que restablecer de forma manual la instancia de base de datos. Google Cloud cambiará automáticamente la instancia secundaria a principal, lo que mantiene así la disponibilidad de la base de datos.

5.5 | Análisis de la pregunta de diagnóstico 10



Estás ejecutando una canalización de Dataflow en producción. En ocasiones, los datos de entrada para esta canalización son incoherentes. Además de procesar los datos válidos, deseas capturar de forma eficaz los datos de entrada erróneos para su análisis.

¿Qué deberías hacer?

- A. Volver a leer los datos de entrada y crear salidas independientes para los datos válidos y erróneos
- B. Leer los datos una vez y dividirlos en dos canalizaciones, una para generar datos válidos y otra para generar datos erróneos
- C. Verificar la existencia de datos erróneos en los registros
- D. Crear una salida complementaria para los datos erróneos

Google Cloud

Comentarios:

- A. Incorrecto. Volver a leer los datos de entrada para procesar solamente los datos erróneos no es eficiente.
- B. Incorrecto. Usar canalizaciones independientes para los mismos datos (una para procesar datos correctos y la otra para datos erróneos) no es eficiente.
- C. Incorrecto. Los datos erróneos no están disponibles automáticamente en los registros.
- D. Correcto. El uso de salidas complementarias puede recopilar los datos erróneos de forma eficaz y es un enfoque recomendado.

Vínculos:

<https://beam.apache.org/documentation/pipelines/design-your-pipeline/#a-single-transform-that-produces-multiple-outputs>

Más información:

Cursos:

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Estado y temporizadores
- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Solución de problemas y depuración
- Confiabilidad

Resumen:

El Professional Data Engineer puede crear canalizaciones de Dataflow y así dividir de manera eficaz una única transformación de modo que se puedan generar resultados para varias PCollections. Los volúmenes de datos por lotes pueden ser grandes y las canalizaciones de datos de transmisión pueden ser continuas, por lo que volver a leer los datos de entrada suele ser ineficaz o imposible. En esos casos, el procesamiento puede producir varias salidas.

5.5 Reconocimiento de las fallas y mitigación del impacto

Cursos

[Moderniza data lakes y almacenes de datos en Google Cloud](#)

- Cómo crear un data lake

[Procesamiento de datos sin servidores con Dataflow: desarrolla canalizaciones](#)

- Estado y temporizadores
- Prácticas recomendadas

[Procesamiento de datos sin servidores con Dataflow: Operaciones](#)

- Solución de problemas y depuración
- Confiabilidad

Documentación

[Usa instantáneas de Dataflow | Google Cloud](#)

[Acerca de la alta disponibilidad | Cloud SQL para MySQL](#)

[Diseña tu canalización](#)

Acabas de revisar preguntas de diagnóstico que abordaron consideraciones relacionadas con el reconocimiento de las fallas y la mitigación de su impacto. Estos son algunos cursos, insignias de habilidad y vínculos para obtener más información sobre los conceptos mencionados en estas preguntas. Ofrecen un punto de partida para explorar las prácticas recomendadas de Google.

<https://cloud.google.com/dataflow/docs/guides/using-snapshots>

<https://cloud.google.com/sql/docs/mysql/high-availability>

<https://beam.apache.org/documentation/pipelines/design-your-pipeline/#a-single-transform-that-produces-multiple-outputs>